

Определения и формулировки

1. Положительно определённая матрица.

💡 Матрица $A \in \mathbb{S}$ называется положительно (отрицательно) определённой, если для $\forall x \neq 0 : x^T A x > (<) 0$. Обозначение: $A \succ 0$ ($A \prec 0$).
Аналогично определяется полуопределённость, только там неравенства нестрогие.

2. Евклидова норма вектора.



$$\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$$

Данная норма соответствует расстоянию в реальном мире. Иначе называется 2-норма (см. p-норма вектора)

3. p-норма вектора.



$$\|x\|_p = \left(\sum_{i=0}^n |x_i|^p \right)^{\frac{1}{p}}$$

Важные частные случаи:

- Норма Чебышева: $\|x\|_\infty = \max_i |x_i|$
- Манхэттенское расстояние или L1 норма: $\|x\|_1 = \sum_{i=0}^n |x_i|$

4. Как выглядит единичный шар в p - норме на плоскости для $p = 1, 2, \infty$?




Рисунок 1: Шары в разных нормах

5. Норма Фробениуса для матрицы.



$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}}$$

6. Спектральная норма матрицы.



$$\|A\|_2 = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sigma_1(A) = \sqrt{\lambda_{\max}(A^T A)}$$

Где $\sigma_1(A)$ – старшее сингулярное значение A , $\lambda_{\max}(A^T A)$ – наибольшее собственное значение $A^T A$.

7. Скалярное произведение двух векторов.



Пусть $x, y \in \mathbb{R}^n$, тогда их скалярное произведение это

$$\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i = y^T x = \langle y, x \rangle$$

8. Скалярное произведение двух матриц, согласованное с нормой Фробениуса.



Пусть $X, Y \in \mathbb{R}^{m \times n}$, тогда их скалярное произведение это

$$\langle X, Y \rangle = \text{tr}(X^T Y) = \sum_{i=1}^m \sum_{j=1}^n X_{ij} Y_{ij} = \text{tr}(Y^T X) = \langle Y, X \rangle$$

Связь с нормой Фробениуса: $\langle X, X \rangle = \|X\|_F^2$

9. Собственные значения матрицы. Спектр матрицы.



Скаляр λ является собственным значением для матрицы A , если существует вектор q , такой что $Aq = \lambda q$. В таком случае q называют собственным вектором.
Спектр матрицы – совокупность её собственных значений.

10. Связь спектра матрицы и её определенности.



Матрица положительно (неотрицательно) определена $\iff$ её спектр (все её собственные значения) положителен (неотрицателен).

11. Спектральное разложение матрицы.

💡 Спектральное разложение матрицы, или разложение матрицы на основе собственных векторов, — это представление квадратной матрицы A в виде произведения трёх матриц $A = S\Lambda S^{-1}$, где S — матрица, столбцы которой являются собственными векторами матрицы A , Λ — диагональная матрица с соответствующими собственными значениями на главной диагонали. В таком виде могут быть представлены только матрицы, обладающие полным набором собственных векторов.




Рисунок 2: Спектральное разложение матрицы

12. Сингулярное разложение матрицы.

💡 $A \in \mathbb{R}^{m \times n}$, $\text{rank } A = r$.

$$A = U\Sigma V^T$$

$U \in \mathbb{R}^{m \times r}$, $U^T U = I$, $V \in \mathbb{R}^{n \times r}$, $V^T V = I$, Σ is a diagonal matrix with

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$$

such that

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$$

Столбцы U , V - левые и правые собственные векторы A , σ_i - сингулярные значения.

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T$$




Рисунок 3: Сингулярное разложение матрицы

13. Связь определителя и собственных чисел для квадратной матрицы.

💡 Если у матрицы A собственные значения $\lambda_1, \lambda_2, \dots, \lambda_n$, то её определитель равен:

$$\det(A) = \lambda_1 \cdot \lambda_2 \cdot \dots \cdot \lambda_n$$

14. Связь следа и собственных чисел для квадратной матрицы.

💡 Если у матрицы A собственные значения $\lambda_1, \lambda_2, \dots, \lambda_n$, то её след равен:

$$\text{tr}(A) = \lambda_1 + \lambda_2 + \dots + \lambda_n$$

15. Линейная сходимость последовательности.

💡 Пусть есть последовательность $\{r_k\}_{k=m}^{\infty} = \{\|x_k - x^*\|_2\}$ в $\mathbb{R}$, сходящаяся к 0. **Линейная сходимость** последовательности $\{r_k\}_{k=m}^{\infty}$ определяется следующим образом: Если существует константа $C > 0$ такая, что:

$$r_k \leq Cq^k, \quad \text{для всех } k \geq m.$$

Если такое q существует, то последовательность называется линейно сходящейся. Точная нижняя граница всех q , удовлетворяющих неравенству, называется **скоростью линейной сходимости** последовательности.

16. Сублинейная сходимость последовательности.

💡 Если последовательность r_k сходится к нулю, но не обладает линейной сходимостью, то говорят, что она сходится сублинейно. Иногда мы можем рассматривать следующий класс сублинейной сходимости:

$$|x_{k+1} - x^*|_2 \leq Ck^q,$$

где $q < 0$ и $0 < C < \infty$.

17. Сверхлинейная сходимость последовательности.

💡 Мы определяем сверхлинейную сходимость как сходимость последовательности, которая быстрее любой линейной сходимости. Иногда рассматривают более специальный класс. Тогда говорят, что сверхлинейная сходимость при $q > 1, C > 0$ определяется следующим образом:

$$|x_{k+1} - x^*| \leq C|x_k - x^*|^q$$

18. Квадратичная сходимость последовательности.

- 💡 Последовательность $\{r_k\}_{k=m}^\infty$ называется **сходящейся сверхлинейно**, если она сходится к нулю быстрее любой линейно сходящейся последовательности.
Для $p > 1$, последовательность имеет **сверхлинейную сходимость порядка p** , если существуют $C > 0$ и $0 < q < 1$ такие, что:

$$r_k \leq Cq^{p^k}, \quad \text{для всех } k \geq m.$$

Когда $p = 2$, это называется **квадратичной сходимостью**.

19. Рассмотрим итеративный процесс $x_k \in \mathbb{R}$, сходящийся к решению $x^* \in \mathbb{R}$ квадратично. Как изменяется количество верных значащих цифр в решении после одной итерации метода?

- 💡 Удваивается.
Пояснение: Пусть $x^* = 1.23456789012345$ (истинное решение), и итерационная последовательность начинается с ошибкой $r_k = 10^{-3}$, соответствующей 3 верным значащим цифрам (1.234).
После первой итерации:

$$r_{k+1} \approx r_k^2 = (10^{-3})^2 = 10^{-6}.$$

Теперь ошибка равна 10^{-6} , и мы имеем 6 верных значащих цифр (1.23456).

После второй итерации:

$$r_{k+2} \approx r_{k+1}^2 = (10^{-6})^2 = 10^{-12}.$$

Теперь ошибка равна 10^{-12} , и мы имеем 12 верных значащих цифр (1.234567890123).

20. Тест корней для определения скорости сходимости последовательности.

- 💡 Пусть $(r_k)_{k=m}^\infty$ - последовательность неотрицательных чисел, сходящаяся к нулю, и пусть $\alpha := \limsup_{k \rightarrow \infty} r_k^{1/k}$. (Заметим, что $\alpha \geq 0$.)

1. Если $0 \leq \alpha < 1$, то $(r_k)_{k=m}^\infty$ сходится линейно с константой α .
2. В частности, если $\alpha = 0$, то $(r_k)_{k=m}^\infty$ сходится сверхлинейно.
3. Если $\alpha = 1$, то $(r_k)_{k=m}^\infty$ сходится сублинейно.
4. Случай $\alpha > 1$ невозможен.

21. Тест отношений для определения скорости сходимости последовательности.

💡 Пусть $r_{k=m}^\infty$ - последовательность строго положительных чисел, сходящаяся к нулю. Пусть

$$q = \lim_{k \rightarrow \infty} \frac{r_{k+1}}{r_k}$$

1. Если существует q и $0 \leq q < 1$, то $r_{k=m}^\infty$ имеет линейную сходимость с константой q .
2. В частности, если $q = 0$, то $r_{k=m}^\infty$ имеет сверхлинейную сходимость.
3. Если q не существует, но $q = \lim_{k \rightarrow \infty} \sup_k \frac{r_{k+1}}{r_k} < 1$, то $r_{k=m}^\infty$ имеет линейную сходимость с константой, не превышающей q .
4. Если $\lim_{k \rightarrow \infty} \inf_k \frac{r_{k+1}}{r_k} = 1$, то $r_{k=m}^\infty$ имеет сублинейную сходимость.
5. Случай $\lim_{k \rightarrow \infty} \inf_k \frac{r_{k+1}}{r_k} > 1$ невозможен.

22. Унимодальная функция.

💡 Функция $f(x)$ называется унимодальной на $[a, b]$, если существует $x^* \in [a, b]$, такое, что

1. $f(x_1) > f(x_2)$ для всех $a \leq x_1 < x_2 < x^*$
2. $f(x_1) < f(x_2)$ для всех $x^* < x_1 < x_2 \leq b$

23. Метод дихотомии.

💡 Наша цель - решить следующую задачу: $\min_{x \in [a,b]} f(x)$. Мы делим отрезок на две равные части и выбираем ту, которая содержит решение задачи, используя значения функции, опираясь на ключевое свойство, описанное выше. Наша цель после одной итерации метода - уменьшить область поиска решения в два раза (в среднем). Метод описан на рисунках ниже.




Рисунок 4: Диаграмма метода дихотомии

Длина отрезка на k -ой итерации:

$$\Delta_k = b_k - a_k = \frac{1}{2^k}(b - a)$$

Для унимодальных функций:

$$|x_k - x^*| \leq \frac{\Delta_k}{2} \leq \frac{1}{2^{k+1}}(b - a) \leq (0.5)^k \cdot \frac{b - a}{2}$$

Заметим, что на каждой итерации мы обращаемся к оракулу не более чем два раза, поэтому число вычислений функции равно $N = 2 \cdot k$, что подразумевает:

$$|x_k - x^*| \leq (0.5)^{\frac{N}{2}+1} \cdot (b - a) \leq (0.707)^N \frac{b - a}{2}$$

24. Метод золотого сечения.

- 💡 Общая идея: хотим поделить отрезок на 3 части так, чтобы потом когда одна из частей отпадет на следующей итерации одно из нужных значений функций будет уже известно.




Рисунок 5: Иллюстрация метода золотого сечения

```
def golden_search(f, a, b, epsilon):  
    tau = (sqrt(5) + 1) / 2  
    y = a + (b - a) / tau**2  
    z = a + (b - a) / tau  
    while b - a > epsilon:  
        if f(y) <= f(z):  
            b = z  
            z = y  
            y = a + (b - a) / tau**2  
        else:  
            a = y  
            y = z  
            z = a + (b - a) / tau  
    return (a + b) / 2
```

25. Метод параболической интерполяции.

💡 Идея метода: берем 3 точки, по этим 3 точкам однозначно строим параболу, находим ее минимум, и из этих 4 точек оставляем 3 так, чтобы между первой и третьей находился минимум.

```
def parabola_search(f, x1, x2, x3, epsilon):
    f1, f2, f3 = f(x1), f(x2), f(x3)
    while x3 - x1 > epsilon:
        u = x2 - ((x2 - x1)**2*(f2 - f3)
        - (x2 - x3)**2*(f2 - f1))/(2*((x2 - x1)*(f2 - f3)
        - (x2 - x3)*(f2 - f1)))
        fu = f(u)

        if x2 <= u:
            if f2 <= fu:
                x1, x2, x3 = x1, x2, u
                f1, f2, f3 = f1, f2, fu
            else:
                x1, x2, x3 = x2, u, x3
                f1, f2, f3 = f2, fu, f3
        else:
            if fu <= f2:
                x1, x2, x3 = x1, u, x2
                f1, f2, f3 = f1, fu, f2
            else:
                x1, x2, x3 = u, x2, x3
                f1, f2, f3 = fu, f2, f3
    return (x1 + x3) / 2
```

Сходится сверхлинейно, но метод довольно неустойчивый. Если $f(x)$ не похожа на параболу, гарантий сходимости нет.

26. Условие достаточного убывания для неточного линейного поиска.

💡 Неточный линейный поиск:

$$x_{k+1} = x_k - \alpha \nabla f(x_k) \alpha = \operatorname{argmin} f(x_{k+1})$$

Хотим приближенно найти α . Сведем задачу к поиску минимума следующей функции:

$$\phi(\alpha) = f(x_k - \alpha \nabla f(x_k)), \alpha \geq 0$$

Приближим ее через первые 2 члена ряда Тейлора:

$$\phi(\alpha) \approx f(x_k) - \alpha \nabla f(x_k)^\top \nabla f(x_k)$$

Тогда условием достаточного убывания (Armijo condition) является:

$$f(x_k - \alpha \nabla f(x_k)) \leq f(x_k) - c_1 \cdot \alpha \nabla f(x_k)^\top \nabla f(x_k), c_1 \in (0, 1)$$

Иллюстрация для понимания:




Рисунок 6: Иллюстрация условия достаточного убывания

27. Условия Гольдштейна для неточного линейного поиска.

💡 Определим ϕ_1 и ϕ_2 следующим образом ($c_1 > c_2$)

$$\phi_1(\alpha) = f(x_k) - c_1 \alpha \|\nabla f(x_k)\|^2$$

$$\phi_2(\alpha) = f(x_k) - c_2 \alpha \|\nabla f(x_k)\|^2$$

Тогда условие Гольдштейна заключается в том, что $\phi_1(\alpha) \leq \phi(\alpha) \leq \phi_2(\alpha)$.

Иллюстрация для понимания:




Рисунок 7: Иллюстрация условий Гольдштейна

28. Условие ограничения на кривизну для неточного линейного поиска.



$$-\nabla f(x_k - \alpha \nabla f(x_k))^\top \nabla f(x_k) \geq c_2 \nabla f(x_k)^\top (-\nabla f(x_k)),$$

где $c_2 \in (c_1, 1)$, и c_1 взято из условия достаточного убывания.

Иллюстрация для понимания:




Рисунок 8: Иллюстрация условия ограничения на кривизну

29. Градиент функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$.

💡 $\nabla f(x)$, вектор частных производных функции f .

30. Гессиан функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$.



$$f''(x) = \nabla^2 f(x) = \frac{\partial^2 f}{\partial x_i \partial x_j} = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{pmatrix}$$

31. Якобиан функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}^m$.



$$J_f = f'(x) = \frac{df}{dx^T} = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{pmatrix}$$

32. Формула для аппроксимации Тейлора первого порядка $f_{x_0}^I(x)$ функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ в точке x_0 .

💡 Для дифференцируемой f :

$$f_{x_0}^I(x) = f(x_0) + \nabla f(x_0)^T (x - x_0)$$

33. Формула для аппроксимации Тейлора второго порядка $f_{x_0}^{II}(x)$ функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ в точке x_0 .

💡 Для дважды дифференцируемой f :

$$f_{x_0}^{II}(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x_0) (x - x_0)$$

34. Связь дифференциала функции df и градиента ∇f для функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$.



$$df(x) = \langle \nabla f(x), dx \rangle$$

35. Связь второго дифференциала функции $d^2 f$ и гессиана $\nabla^2 f$ для функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$.



$$d(df) = d^2 f(x) = \langle \nabla^2 f(x) dx_1, dx \rangle = \langle H_f(x) dx_1, dx \rangle$$

36. Формула для приближенного вычисления производной функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ по k -ой координате с помощью метода конечных разностей.



$$\frac{\partial f}{\partial x_k}(x) \approx \frac{f(x + \varepsilon e_k) - f(x)}{\varepsilon}, \quad e_k = (0, \dots, 1_k, \dots, 0)$$

Время работы: $2dT$, где вызов $f(x)$ занимает $T, x \in \mathbb{R}^d$

37. Пусть $f = f(x_1(t), \dots, x_n(t))$. Формула для вычисления $\frac{\partial f}{\partial t}$ через $\frac{\partial x_i}{\partial t}$ (Forward chain rule).



$$\frac{\partial f}{\partial t} = \sum_{i=1}^n \frac{\partial f}{\partial x_i} \frac{\partial x_i}{\partial t}$$

38. Пусть L - функция, возвращающая скаляр, а v_k - функция, возвращающая вектор $x \in \mathbb{R}^t$. Формула для вычисления $\frac{\partial L}{\partial v_k}$ через $\frac{\partial L}{\partial x_i}$ (Backward chain rule).



$$\frac{\partial L}{\partial v_k} = \sum_{i=1}^t \frac{\partial L}{\partial x_i} \frac{\partial x_i}{\partial v_k}$$

39. Идея Хатчинсона для оценки следа матрицы с помощью matvec операций.



$X \in \mathbb{R}^{d \times d}$, $v \in \mathbb{R}^d$ - случайный вектор: $\mathbb{E}[vv^T] = I$, на каждой координате которого с одинаковой вероятностью стоит 1 или -1 .

$$\text{Tr}(X) = \mathbb{E}[v^T X v] = \frac{1}{V} \sum_{i=1}^V v_i^T X v_i.$$

40. Аффинное множество. Аффинная комбинация. Аффинная оболочка.



Множество A называется аффинным если для любых x_1, x_2 из A прямая, проходящая через x_1, x_2 , тоже лежит в A . То есть:

$$\forall \theta \in \mathbb{R}, \forall x_1, x_2 \in A : \theta x_1 + (1 - \theta) x_2 \in A$$

Пример аффинного множества: $\mathbb{R}^n$

Пусть $x_1, x_2, \dots, x_k \in S$. Тогда точка $\theta_1 x_1 + \theta_2 x_2 + \dots + \theta_k x_k$ называется аффинной комбинацией, если

$$\forall i \in \{1, \dots, k\} : \theta_i \in \mathbb{R}, \quad \sum_{i=1}^k \theta_i = 1$$

Аффинная оболочка – множество всех возможных аффинных комбинаций элементов множества.

$$\text{aff}(S) = \left\{ \sum_{i=1}^k \theta_i x_i \mid k > 0, x_i \in S, \theta_i \in \mathbb{R}, \sum_{i=1}^k \theta_i = 1 \right\}$$

41. Выпуклое множество. Выпуклая комбинация. Выпуклая оболочка.

💡 Множество S называется выпуклым если для любых x_1, x_2 из S отрезок между x_1, x_2 тоже лежит в S . То есть:

$$\forall \theta \in [0, 1], \forall x_1, x_2 \in S : \theta x_1 + (1 - \theta) x_2 \in S$$

Пусть $x_1, x_2, \dots, x_k \in S$. Тогда точка $\theta_1 x_1 + \theta_2 x_2 + \dots + \theta_k x_k$ называется выпуклой комбинацией, если

$$\forall i \in \{1, \dots, k\} : \theta_i \geq 0, \quad \sum_{i=1}^k \theta_i = 1$$

Выпуклая оболочка – множество всех возможных выпуклых комбинаций элементов множества.

$$\text{conv}(S) = \left\{ \sum_{i=1}^k \theta_i x_i \mid k > 0, x_i \in S, \theta_i \geq 0, \sum_{i=1}^k \theta_i = 1 \right\}$$

42. Конус. Выпуклый конус. Коническая комбинация. Коническая оболочка.

💡 Множество S называется конусом если для любого x из S луч, проходящий из 0 через x , тоже лежит в S . То есть:

$$\forall \theta \geq 0, \forall x \in S : \theta x \in S$$

Множество S называется выпуклым конусом если для любых $x_1, x_2 \in S$ их коническая комбинация тоже лежит в S . То есть:

$$\forall x_1, x_2 \in S, \theta_1, \theta_2 \geq 0 : \theta_1 x_1 + \theta_2 x_2 \in S$$

Пусть $x_1, x_2, \dots, x_k \in S$. Тогда точка $\theta_1 x_1 + \theta_2 x_2 + \dots + \theta_k x_k$ называется конической комбинацией, если

$$\forall i \in \{1, \dots, k\} : \theta_i \geq 0$$

Коническая оболочка - множество всех возможных конических комбинаций элементов множества.

$$\text{con}(S) = \left\{ \sum_{i=1}^k \theta_i x_i \mid k > 0, x_i \in S, \theta_i \geq 0 \right\}$$

43. Внутренность множества.

💡 Внутренность множества - совокупность всех точек множества, содержащих вместе с собой в множестве некоторую окрестность вокруг себя.


44. Относительная внутренность множества.

- 💡 Относительная внутренность множества - внутренность множества в его аффинной оболочке. Может быть полезной при работе с множествами меньшей размерности чем пространство, в котором они находятся.

$$\text{relint}(S) = \{x \in S \mid \exists \varepsilon > 0, N_\varepsilon(x) \cap \text{aff}(S) \subseteq S\}$$

$N_\varepsilon(x)$ – шар радиуса ε с центром в x , $\text{aff}(S)$ – аффинная оболочка S


Пример: отрезок на плоскости имеет пустую внутренность, но его относительная внутренность – тот же отрезок без концов.



45. Сумма Минковского.

- 💡 Сумма Минковского – евклидово пространство, формирующееся сложением каждого вектора из S_1 с каждым вектором из S_2 :

$$S_1 + S_2 = \{s_1 + s_2 \mid s_1 \in S_1, s_2 \in S_2\}$$



46. Любые 2 операции с множествами, сохраняющие выпуклость.



1. Линейная комбинация:

$$S = \{s \mid s = c_1x + c_2y, x \in S_x, y \in S_y, c_1, c_2 \in \mathbb{R}\}$$

2. Пересечение любого числа выпуклых множеств

3. Образ множества в аффинном преобразовании:

$$S \subseteq \mathbb{R}^n \text{ convex} \rightarrow f(S) = \{f(x) \mid x \in S\} \text{ convex} \quad (f(x) = Ax + b)$$

47. Выпуклая функция.



Функция $f(x)$, определённая на выпуклом множестве $S \subseteq \mathbb{R}^n$ называется выпуклой на S если:

$$\forall x_1, x_2 \in S, \quad \forall \lambda \in [0, 1]$$

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$$




Рисунок 9: Иллюстрация выпуклой функции

48. Строго выпуклая функция.



Функция $f(x)$, определённая на выпуклом множестве $S \subseteq \mathbb{R}^n$ называется строго выпуклой на S если:

$$\forall x_1, x_2 \in S : x_1 \neq x_2, \quad \forall \lambda \in (0, 1)$$

$$f(\lambda x_1 + (1 - \lambda)x_2) < \lambda f(x_1) + (1 - \lambda)f(x_2)$$

49. Надграфик функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$.

💡 Для функции, определённой на $S \subseteq \mathbb{R}^n$, множество:

$$\text{epi } f = \{[x, \mu] \in S \times \mathbb{R} : f(x) \leq \mu\}$$

называется надграфиком функции $f(x)$.




Рисунок 10: Иллюстрация надграфика функции

50. Множество подуровней функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$.

💡 Для функции, определённой на $S \subseteq \mathbb{R}^n$, множество:

$$\mathcal{L}_\beta = \{x \in S : f(x) \leq \beta\}$$

называется множеством подуровней или множеством Лебега функции $f(x)$

Если функция $f(x)$ выпукла, то её множество подуровней выпукло для любого $\beta \in \mathbb{R}$.

Обратное неверно. (Например, рассмотрим функцию $f(x) = \sqrt{|x|}$)




Рисунок 11: Иллюстрация множества подуровней функции

51. Дифференциальный критерий выпуклости первого порядка.

💡 Дифференцируемая функция определенная на выпуклом множестве $S \subseteq \mathbb{R}^n$ выпукла тогда и только тогда когда $\forall x, y \in S$:

$$f(y) \geq f(x) + \nabla f^T(x)(y - x)$$

52. Дифференциальный критерий выпуклости второго порядка.

💡 Дважды дифференцируемая функция определенная на выпуклом множестве $S \subseteq \mathbb{R}^n$ выпукла тогда и только тогда когда для любой внутренней точки $x \forall x \in \text{int}(S) \neq \emptyset$:

$$\nabla^2 f(x) \succeq 0$$

53. Связь выпуклости функции и её надграфика.

💡 Функция выпукла тогда и только тогда, когда её надграфик - выпуклое множество.

54. μ -сильно выпуклая функция.

- 💡 Функция определенная на выпуклом множестве $S \subseteq \mathbb{R}^n$ называется сильно выпуклой если $\forall x_1, x_2 \in S, \forall 0 \leq \lambda \leq 1$ и $\mu > 0$:

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2) - \frac{\mu}{2} \lambda(1 - \lambda) \|x_1 - x_2\|^2$$

55. Дифференциальный критерий сильной выпуклости первого порядка.

- 💡 Дифференцируемая функция определенная на выпуклом множестве $S \subseteq \mathbb{R}^n$ является сильно выпуклой тогда и только тогда, когда $\forall x, y \in S$:

$$f(y) \geq f(x) + \nabla f^T(x)(y - x) + \frac{\mu}{2} \|y - x\|^2$$

56. Дифференциальный критерий сильной выпуклости второго порядка.

- 💡 Дважды дифференцируемая функция определенная на выпуклом множестве $S \subseteq \mathbb{R}^n$ является сильно выпуклой тогда и только тогда, когда существует $\mu > 0$

$$\nabla^2 f(x) \succeq \mu I$$

57. Любые 2 операции с функциями, сохраняющие выпуклость.

- 💡
1. Сумма выпуклых функций с не отрицательными коэффициентами является выпуклой функцией.
 2. Композиция выпуклой функции с афинной выпукла: $g(x) = f(Ax + b)$
 3. Поточечный максимум любого числа выпуклых функций есть выпуклая функция.

58. Теорема Тейлора.

- 💡 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ - непрерывная, дифференцируемая функция и $p \in \mathbb{R}^n$, тогда теорема Тейлора гласит:

$$f(x + p) = f(x) + \nabla f(x + tp)^T p$$

Для некоторого $t \in (0, 1)$

Более того, если f - дважды дифференцируема, то:

$$f(x + p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x + tp) p$$

Для некоторого $t \in (0, 1)$

59. Необходимые условия локального экстремума.

- 💡 Если x^* - локальный экстремум и f непрерывно дифференцируема в открытой окрестности x^* , то:

$$\nabla f(x^*) = 0$$

60. Достаточные условия локального экстремума.

💡 Если $\nabla^2 f$ непрерывна в открытой окрестности x^* и

$$\nabla f(x^*) = 0$$

$$\nabla^2 f(x^*) \succ 0$$

То x^* - локальный минимум $f(x)$. Для локального максимума аналогично, только

$$0 \succ \nabla^2 f(x^*)$$

61. Общая задача математического программирования. Функция Лагранжа.



$$\begin{cases} f_0(x) \rightarrow \min_{x \in \mathbb{R}^d} \\ f_i(x) \leq 0, \quad i = 1, \dots, m, \\ h_i(x) = 0, \quad i = 1, \dots, p. \end{cases}$$

Функция Лагранжа:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x),$$

62. Теорема Каруша - Куна - Таккера в форме необходимых условий решения задачи математического программирования.

💡 Пусть x_* - решение задачи с нулевым зазором двойственности

$$\begin{cases} f_0(x) \rightarrow \min_{x \in \mathbb{R}^d} \\ f_i(x) \leq 0, \quad i = 1, \dots, m, \\ h_i(x) = 0, \quad i = 1, \dots, p. \end{cases}$$

Функция Лагранжа:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x),$$

Тогда найдутся такие векторы λ^* и ν^* , что выполнены условия

$$\begin{cases} \nabla f_0(x_*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x_*) + \sum_{i=1}^p \nu_i^* \nabla h_i(x_*) = 0 \\ f_i(x_*) \leq 0, \quad i = 1, \dots, m \\ h_i(x_*) = 0, \quad i = 1, \dots, p \\ \lambda_i^* \geq 0, \quad i = 1, \dots, m \\ \lambda_i^* f_i(x_*) = 0, \quad i = 1, \dots, m \end{cases}$$

63. Условие Слейтера.



1. Если задача выпуклая (т.е., говоря о задаче минимизации, оптимизируемая функция f_0 и ограничения вида неравенство f_i – выпуклые, ограничения вида равенства h_i – аффинные)
2. И существует точка x такая, что $h(x) = 0$ и $f_i(x) < 0$ (ограничения вида равенства активные, а ограничения вида неравенства выполняются строго)

То тогда задача имеет нулевой зазор двойственности и условия ККТ становятся необходимыми и достаточными.

64. Задача выпуклого программирования.



Задача выпуклого программирования — это задача оптимизации, в которой целевая функция является выпуклой функцией и область допустимых решений выпукла. В форме ниже функции $f_0, \dots, f_m$ – выпуклые, а функции h_i – аффинные.

$$\begin{cases} f_0(x) \rightarrow \min_{x \in \mathbb{R}^d} \\ f_i(x) \leq 0, & i = 1, \dots, m, \\ h_i(x) = 0, & i = 1, \dots, p. \end{cases}$$

65. Двойственная функция в задаче математического программирования.



Предположим, что $D = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=0}^p \text{dom } h_i$ непустое. Определим двойственную функцию $g : \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$ как минимум лагранжиана по x : для $\lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p$

$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) = \inf_{x \in D} f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

Так как двойственная функция это поточечный инфимум семейства аффинных функций от (λ, ν) , она вогнутая, даже если изначальная задача не выпуклая.

66. Двойственная задача для задачи математического программирования.

💡 Пусть p^* - оптимальное решение изначальной задачи. Пусть $\hat{x}$ достижимая точка для изначальной задачи, т.е. $f_i(\hat{x}) \leq 0$ and $h_i(\hat{x}) = 0, \lambda \geq 0$. Тогда имеем:

$$L(\hat{x}, \lambda, \nu) = f_0(\hat{x}) + \underbrace{\lambda^T f(\hat{x})}_{\leq 0} + \underbrace{\nu^T h(\hat{x})}_{=0} \leq f_0(\hat{x})$$

Тогда

$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) \leq L(\hat{x}, \lambda, \nu) \leq f_0(\hat{x})$$

$$g(\lambda, \nu) \leq p^*$$

Двойственной задачей называется

$$g(\lambda, \nu) \rightarrow \max_{\lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p}$$

$$s.t. \lambda \geq 0$$

67. Сильная двойственность. Зазор двойственности.

💡 Пусть p^* - решение прямой задачи, d^* - решение двойственной задачи. Зазором двойственности называется

$$p^* - d^* \geq 0$$

Сильная двойственность возникает, если зазор равен нулю

$$p^* = d^*$$

68. Локальный анализ чувствительности с помощью множителей Лагранжа.

💡 Перейдем к возмущенной версии задачи:

$$f_0(x) \rightarrow \min_x$$

$$f_i(x) \leq u_i, \quad i = 1, \dots, m$$

$$h_i(x) = v_i, \quad i = 1, \dots, p,$$

Обозначим $p^*(u, v)$ - оптимальное решение этой задачи. Если имеет место сильная двойственность, то выполнено:

$$p^*(u, v) \geq p^*(0, 0) - \lambda^{*T} u - \nu^{*T} v$$

Если множители Лагранжа λ_i^*, ν_i^* большие, то небольшое изменение ограничений приведет к существенному изменению оптимального решения. То есть соответствующие ограничения очень сильно влияют на задачу. \ Если множители Лагранжа маленькие, то соответствующие ограничения мало влияют на задачу.

$$\lambda_i^* = -\frac{\partial p^*(0, 0)}{\partial u_i} \quad \nu_i^* = -\frac{\partial p^*(0, 0)}{\partial v_i}$$

69. Задача линейного программирования. Задача линейного программирования в стандартной форме.

- 💡 Все задачи с линейным функционалом и линейными ограничениями считаются задачами линейного программирования. Стандартная форма:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & x_i \geq 0, i = 1, \dots, n \end{aligned}$$

70. Возможные случаи двойственности в задаче линейного программирования.

- 💡 Двойственная задача:

$$\begin{aligned} \max_{\nu \in \mathbb{R}^m} \quad & -b^T \nu \\ \text{s.t.} \quad & -A^T \nu \leq c \end{aligned}$$

1. Если либо у прямой, либо у двойственной задачи есть конечное решение, то и у другой тоже, и оптимальные значения задач равны.
2. Если либо прямая, либо двойственная задача неограничена, то вторая из них недопустима (бюджетное множество пусто).

71. Симплекс метод.

💡 Симплекс метод решает следующую задачу:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} c^\top x \\ s.t. Ax \leq b \end{aligned}$$

Шаги выполнения симплекс метода:

1. **Поиск начальной базисной допустимой точки:** Выберем начальную базисную (она является решением системы $A_B x = b_B$, где B - базис размера n пространства, а матрица A обычно имеет больше n ограничений) допустимую ($Ax_0 \leq b$) точку x_0 (искать ее будем через двухфазный симплексметод). Если такая точка не найдена, задача не имеет допустимого решения.

2. **Проверка оптимальности:**

- Разложение вектора c в данном базисе B с коэффициентами λ_B :

$$\lambda_B^\top A_B = c^\top \quad \text{или} \quad \lambda_B^\top = c^\top A_B^{-1}$$

- Если все компоненты λ_B неположительны, текущий базис является оптимальным. Иначе далее меняем вершину симплекса.

3. **Определение переменной для удаления из базиса:**

4. **Вычисление шага вдоль выбранного направления d :**

- Для всех $j \notin B$ считаем шаг:

$$\mu_j = \frac{b_j - a_j^\top x_B}{a_j^\top d}$$

- Новая вершина, которую добавим в базис:

$$t = \arg \min_j \{\mu_j \mid \mu_j > 0\}$$

5. **Обновление базиса:**

6. **Повторение:**

- Далее повторяем шаги 2-5 до достижения оптимального решения или установления, что задача не имеет допустимого решения.

72. Нахождение первоначальной угловой точки с помощью двухфазного симплекс метода.



1. Рассмотрим задачу (Phase 1):

$$\min_{\xi \in \mathbb{R}^m, y \in \mathbb{R}^n, z \in \mathbb{R}^n} \sum_{i=1}^m \xi_i$$

$$s.t. Ay - Az \leq b + \xi$$

$$y \geq 0, x \geq 0, \xi \geq 0$$

Для нее есть допустимая угловая точка $z = 0, y = 0, \xi_i = \max(0, -b_i)$. Начиная с нее, решим задачу симплекс методом и получим точку оптимума, в которой $\xi = 0$ и выполнены указанные ограничения.

2. Решение задачи Phase 1 является допустимым базисом задачи Phase 2:

$$\min_{y \in \mathbb{R}^n, z \in \mathbb{R}^n} c^\top (y - z)$$

$$s.t. Ay - Az \leq b$$

$$y \geq 0, x \geq 0$$

3. Заметим, что оно так же будет являться допустимым базисом и угловой точкой для исходной задачи:

$$\min_{x \in \mathbb{R}^n} c^\top x$$

$$s.t. Ax \leq b$$

4. Так и нашли первоначальную угловую точку для исходной задачи.

73. Сходимость симплекс метода.



В худшем случае симплекс метод сходится экспоненциально от размерности задачи, но на практике в среднем алгоритм работает сильно лучше. Задача, на которой симплекс метод работает экспоненциальное время, называется примером Klee Minty.

74. Показать, что направление антиградиента - направление наискорейшего локального убывания функции.



Пусть f дифференцируема, зададим искомое направление локального убывания - h - $\|h\| = 1$. Тогда её аппроксимация: $f(x + \alpha h) = f(x) + \alpha \langle \nabla f(x), h \rangle + o(\alpha)$

$$f(x + \alpha h) < f(x) \Rightarrow \alpha \langle \nabla f(x), h \rangle + o(\alpha) < 0.$$

При $\alpha \rightarrow +0$ получаем: $\alpha \langle \nabla f(x), h \rangle \leq 0$

$$\|\langle \nabla f(x), h \rangle\| \leq \|\nabla f(x)\| \|h\| \leq \|\nabla f(x)\|$$

$$\langle \nabla f(x), h \rangle \geq -\|\nabla f(x)\| \Rightarrow h = \frac{-\nabla f(x)}{\|\nabla f(x)\|}, \text{ ч.т.д.}$$

75. Дифференциальное уравнение градиентного потока.



$$\frac{dx}{dt} = -\nabla f(x)$$

76. Метод градиентного спуска.



Решаем задачу минимизации

$$f(x) \rightarrow \min_{x \in \mathbb{R}^d}$$

Если f дифференцируема, то тогда для решения этой задачи можно использовать метод градиентного спуска:

$$x_{k+1} = x_k - \alpha \nabla f(x_k)$$

77. Наискорейший спуск.



Решаем задачу минимизации

$$f(x) \rightarrow \min_{x \in \mathbb{R}^d}$$

Если f дифференцируема, то тогда для решения этой задачи можно использовать метод наискорейшего спуска:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

$$\alpha_k = \arg \min_{\alpha \in \mathbb{R}^+} f(x_k - \alpha \nabla f(x_k)),$$

т.е. выбираем наилучший шаг спуска на каждой итерации метода.

78. Как направлены две соседние итерации метода наискорейшего спуска по отношению друг к другу?



Они ортогональны друг другу.




Рисунок 12: Несколько итераций наискорейшего спуска

79. Липшицева парабола для гладкой функции.

💡 Если $f : \mathbb{R}^n \rightarrow \mathbb{R}$ - непрерывно дифференцируема и градиент Липшицев с константой L , то $\forall x, y \in \mathbb{R}^n$:

$$\|f(y) - f(x) - \langle \nabla f(x), y - x \rangle\| \leq \frac{L}{2} \|y - x\|^2$$

Если зафиксируем $x_0 \in \mathbb{R}^n$, то:

$$\varphi_1(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle - \frac{L}{2} \|x - x_0\|^2$$

$$\varphi_2(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{L}{2} \|x - x_0\|^2$$

Это две параболы, и для них верно, что $\varphi_1(x) \leq f(x) \leq \varphi_2(x) \forall x$




Рисунок 13: Иллюстрация Липшицевых парабол, между которыми зажата гладкая функция. Чаще нас интересует мажорирующая из них.

80. Размер шага наискорейшего спуска для квадратичной функции.

💡 Решаем задачу минимизации методом наискорейшего спуска

$$f(x) = \frac{1}{2}x^T A x - b^T x + c \rightarrow \min_{x \in \mathbb{R}^d}$$

$$\nabla f = \frac{1}{2}(A + A^T)x - b$$

Из условия $\nabla f(x_{k+1})^T \nabla f(x_k) = 0$ получаем:

$$\alpha_k = \frac{2\nabla f(x_k)^T \nabla f(x_k)}{\nabla f(x_k)^T (A + A^T) \nabla f(x_k)} = \frac{\nabla f(x_k)^T \nabla f(x_k)}{\nabla f(x_k)^T \nabla^2 f(x_k) \nabla f(x_k)}.$$

81. Характер сходимости градиентного спуска к локальному экстремуму для гладких невыпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 $\|\nabla f(x_k)\|^2 \sim \mathcal{O}\left(\frac{1}{k}\right).$

82. Характер сходимости градиентного спуска для гладких выпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right).$

83. Характер сходимости градиентного спуска для гладких и сильно выпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 $\|x_k - x^*\|^2 \sim \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right).$

84. Связь спектра гессиана с константами сильной выпуклости и гладкости функции.

💡 $\mu = \min_{x \in \text{dom} f} \lambda_{\min}(\nabla^2 f(x)), \quad L = \max_{x \in \text{dom} f} \lambda_{\max}(\nabla^2 f(x)).$

85. Условие Поляка-Лоясевича (градиентного доминирования) для функций.

💡 $\exists \mu > 0 : \quad \|\nabla f(x)\|^2 \geq 2\mu(f(x) - f^*) \quad \forall x, \text{ где } f^* - \text{минимум функции } f(x).$

86. Сходимость градиентного спуска для сильно выпуклых квадратичных функций. Оптимальные гиперпараметры.

- 💡 Решаем задачу минимизации методом градиентного спуска. Пусть $A \in \mathbb{S}_{++}^n \Rightarrow \nabla f = Ax - b$.

$$f(x) = \frac{1}{2}x^T Ax - b^T x + c \rightarrow \min_{x \in \mathbb{R}^d}$$

$$x_{k+1} = x_k - \alpha(Ax_k - b)$$

$$\alpha_{opt} = \frac{2}{\mu + L}, \text{ где } \mu = \lambda_{\min}(A), L = \lambda_{\max}(A)$$

$$\kappa = \frac{L}{\mu} \geq 1$$

$$\rho = \frac{\kappa - 1}{\kappa + 1}$$

$$\|x_k - x^*\| \leq \rho^k \|x_0 - x^*\|$$

87. Связь PL-функций и сильно выпуклых функций.

- 💡 Пусть f μ -сильно выпуклая и дифференцируемая $\Rightarrow f \in \text{PL}$.
Обратное неверно - $f(x) = x^2 + 3\sin^2 x \in \text{PL}$, но не сильно выпуклая (она вообще не выпуклая).




Рисунок 14: Пример невыпуклой PL функции

88. Привести пример выпуклой, но не сильно выпуклой задачи линейных наименьших квадратов (возможно, с регуляризацией).

- 💡 Рассмотрим задачу минимизации функции:

$$\|Ax - b\|^2 \rightarrow \min_{x \in \mathbb{R}^d},$$

где матрица $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, $m < n$ (лежащая).

89. Привести пример сильно выпуклой задачи линейных наименьших квадратов (возможно, с

регуляризацией).

💡 Рассмотрим задачу минимизации функции:

$$f(x) = \|Ax - b\|_2^2,$$

где $A \in \mathbb{R}^{n \times n}$ (ранг $A = n$). Эта функция сильно выпукла, так как гессиан положительно определен.

90. Нижние оценки для гладкой выпуклой оптимизации с помощью методов первого порядка в терминах $\mathcal{O}$ от числа итераций метода.

💡 $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k^2}\right)$

91. Нижние оценки для гладкой сильно выпуклой оптимизации с помощью методов первого порядка в терминах $\mathcal{O}$ от числа итераций метода.

💡 $\|x^k - x^*\|^2 \sim \mathcal{O}\left(\left(1 - \sqrt{\frac{\mu}{L}}\right)^k\right)$

92. Отличие ускоренной и неускоренной линейной сходимости для методов первого порядка.



Функция	Неускоренная	Ускоренная
Гладкая и выпуклая	$\mathcal{O}\left(\frac{1}{k^2}\right)$	$\mathcal{O}\left(\frac{1}{k}\right)$
Гладкая и сильно-выпуклая (или PL)	$\mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$	$\mathcal{O}\left(\left(1 - \sqrt{\frac{\mu}{L}}\right)^k\right)$

93. Метод тяжелого шарика (Поляка).

💡 Задача: $f(x) \rightarrow \min_{x \in \mathbb{R}^d}$, $f(x)$ - непрерывно дифференцируемая функция

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}), \quad 0 < \beta < 1.$$

94. Понятие локальной и глобальной сходимости численного метода оптимизации.

💡 Локальная сходимость означает, что последовательность итераций сходится к решению x^* внутри некоторого множества. За пределами этого множества сходимости нет. Глобальная сходимость означает, что последовательность итераций сходится к решению x^* вне зависимости от начального приближения.

95. Ускоренный градиентный метод Нестерова для выпуклых гладких функций.

💡 Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ выпуклая и L -гладкая. Ускоренный градиентный метод Нестерова (NAG) имеет вид ($x_0 = y_0$, $\lambda_0 = 0$):

Градиентный шаг: $y_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$

Экстраполяция: $x_{k+1} = (1 - \gamma_k) y_{k+1} + \gamma_k y_k$


Вес экстраполяции: $\lambda_{k+1} = \frac{1 + \sqrt{1 + 4\lambda_k^2}}{2}$

Вес экстраполяции: $\gamma_k = \frac{1 - \lambda_k}{\lambda_{k+1}}$


Последовательность $\{f(y_k)\}_{k \in \mathbb{N}}$ сходится к оптимальному значению f^* со скоростью $\mathcal{O}\left(\frac{1}{k^2}\right)$, а именно:

$$f(y_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}$$

Polyak momentum



Nesterov momentum



96. Ускоренный градиентный метод Нестерова для сильно выпуклых гладких функций.

💡 Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ μ -сильно выпуклая и L -гладкая. Ускоренный градиентный метод Нестерова (NAG) имеет вид ($x_0 = y_0$, $\lambda_0 = 0$):

Градиентный шаг: $y_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$

Экстраполяция: $x_{k+1} = (1 + \gamma_k) y_{k+1} - \gamma_k y_k$

Вес экстраполяции: $\gamma_k = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$

Последовательность $\{f(y_k)\}_{k \in \mathbb{N}}$ сходится к оптимальному значению f^* линейно:

$$f(y_k) - f^* \leq \frac{\mu + L}{2} \|x_0 - x^*\|_2^2 \exp\left(-\frac{k}{\sqrt{\kappa}}\right)$$

97. A -сопряженность двух векторов. A -ортогональность. Скалярное произведение $\langle \cdot, \cdot \rangle_A$.

💡 A -ортогональность (сопряженность):

$$x \perp_A y \iff x^T A y = 0.$$

98. Процедура ортогонализации Грама-Шмидта.

💡 Пусть $a_1, \dots, a_n$ - ЛНЗ векторы и $\text{proj}_b a$ - оператор проекции a на b , определенный как

$$\text{proj}_b a = \frac{\langle a, b \rangle}{\langle b, b \rangle} b,$$

Ортогонализация Грама-Шмидта:


$$b_1 = a_1$$

$$b_2 = a_2 - \text{proj}_{b_1} a_2$$

$$b_3 = a_3 - \text{proj}_{b_1} a_3 - \text{proj}_{b_2} a_3$$

...

$$b_n = a_n - \sum_{i=1}^{n-1} \text{proj}_{b_i} a_n$$



99. Метод сопряженных направлений.

💡 Рассматриваем задачу

$$f(x) = \frac{1}{2}x^T Ax - b^T x + c \rightarrow \min_{x \in \mathbb{R}^d}$$

Идея

- В изотропном $A = I$ мире, наискорейший спуск стартующий из произвольной точки в любом пространстве натянутом на линейную оболочку из n ортогональных ЛН векторов будет сходится за n шагов в точной арифметике. Мы попытаемся в случае $A \neq I$ провести A -ортогонализацию, чтобы “наискорейшим” образом спускаться в измененном базисе.
- Предположим имеется набор из n линейно независимых A -ортогональных векторов(направлений) $d_0, \dots, d_{n-1}$ (которые, например, были получены в ходе A -ортогонализации Г-Ш).
- Мы хотим создать метод, который переходит от x_0 к x^* по указанным ортогональным направлениям с некоторыми шагами, т.е. $x_0 - x^* = \sum_{i=0}^{d-1} \alpha_i d_i$, где α_i - из решения задачи линейного поиска.

100. Метод сопряженных градиентов.

💡 Рассматриваем задачу

$$f(x) = \frac{1}{2}x^T Ax - b^T x + c \rightarrow \min_{x \in \mathbb{R}^d}$$


Метод сопряженных градиентов:

- $r_0 := b - Ax_0$
- if r_0 sufficiently small, then return x_0 as result
- $d_0 := r_0$
- $k := 0$
- while r_{k+1} is not sufficiently small :
 - $\alpha_k := \frac{r_k^T r_k}{d_k^T A d_k}$
 - $x_{k+1} := x_k + \alpha_k d_k$
 - $r_{k+1} := r_k - \alpha_k A d_k$
 - $\beta_k := \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$
 - $d_{k+1} := r_{k+1} + \beta_k d_k$
 - $k := k + 1$
- return x_{k+1} as result.


101. Зависимость сходимости метода сопряженных градиентов от спектра матрицы.

- 💡 Если матрица A имеет только r различных собственных чисел, тогда метод сопряжённых градиентов сходится за r итераций.

Strongly convex quadratics. $n=60$, random matrix.



Strongly convex quadratics. $n=60$, clustered matrix.



102. Характер сходимости метода сопряженных градиентов в терминах $\mathcal{O}$ от числа итераций метода.



$$\|x_k - x^*\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|x_0 - x^*\|_A$$

Имеет место оценка числа итераций при заданной точности ε : $\|x_k - x^*\|_A \leq \varepsilon \|x_0 - x^*\|_A$

$$k \leq \left\lceil \frac{1}{2} \sqrt{\kappa(A)} \ln \left(\frac{2}{\varepsilon} \right) \right\rceil$$

103. Метод Полака-Рибьера.




Используется для минимизации неквадратичных выпуклых функций.


Без знания аналитического выражения шаг 2 алгоритма метода сопряжённых направлений вместо подсчёта α из минимизации $f(x_k + \alpha_k d_k)$ находит α обычным линейным поиском.

$$\beta_k = \frac{\nabla f(x_{k+1})^T (\nabla f(x_{k+1}) - \nabla f(x_k))}{d_k^T (\nabla f(x_{k+1}) - \nabla f(x_k))}$$

Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=0$



Regularized binary logistic regression. $n=300$. $m=1000$. $\mu=1$



104. Метод Ньютона.



Рассматривается задача минимизации функции с невырожденным гессианом.

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

105. Сходимость метода Ньютона для квадратичной функции.



Метод Ньютона сходится для квадратичной функции за одну итерацию, при условии, что гессиан невырожден. Следует из метода Ньютона квадратичной тейлоровской аппроксимации:

$$f(x) = f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k), \quad \nabla f(x_{k+1}) = 0$$

106. Характер сходимости метода Ньютона для сильно выпуклых гладких функций - куда и как сходится.

💡 Пусть $f(x)$ сильно выпукла дважды непрерывно дифференцируемая на $\mathbb{R}^n$ и выполняются неравенства: $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$. Тогда метод Ньютона с постоянным шагом локально сходится к решению со сверхлинейной скоростью. Если вдобавок, Гессиан M -Липшицев, тогда метод сходится локально к x^* с квадратичной скоростью.

107. Демпфированный метод Ньютона.



$$x_{k+1} = x_k - \alpha_k [\nabla^2 f(x_k)]^{-1} \nabla f(x_k), \quad \alpha_k \in [0, 1]$$

где α_k находят с помощью линейного поиска. Сходимость глобальная.

108. Идея квазиньютоновских методов. Метод SR-1.



$$\min_{x \in \mathbb{R}^d} f(x)$$

Пусть $x_0 \in \mathbb{R}^n$, $B_0 \succ 0$. Для $k = 1, 2, 3, \dots$, повторим:

1. Решить $B_k d_k = -\nabla f(x_k)$ относительно d_k .
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$.
3. Вычислить B_{k+1} из B_k .

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}, \quad \Delta y_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$

109. Афинная инвариантность метода Ньютона.



Пусть дана функция f и невырожденная матрица $A \in \mathbb{R}^{n \times n}$, пусть $x = Ay$, и пусть $g(y) = f(Ay)$. Заметим, что $\nabla g(y) = A^T \nabla f(x)$ и $\nabla^2 g(y) = A^T \nabla^2 f(x) A$. Шаги Ньютона на g выражаются как:

$$y_{k+1} = y_k - (\nabla^2 g(y_k))^{-1} \nabla g(y_k)$$

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k)$$

Пояснение:

$$y_{k+1} = y_k - (A^T \nabla^2 f(Ay_k) A)^{-1} A^T \nabla f(Ay_k)$$

Используя свойство обратной матрицы $(AB)^{-1} = B^{-1} A^{-1}$, это упрощается до:

$$y_{k+1} = y_k - A^{-1} (\nabla^2 f(Ay_k))^{-1} \nabla f(Ay_k)$$

$$Ay_{k+1} = Ay_k - (\nabla^2 f(Ay_k))^{-1} \nabla f(Ay_k)$$

Таким образом, правило обновления для x выглядит так:

$$x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1} \nabla f(x_k)$$

Это показывает, что итерация метода Ньютона, не зависит от масштаба задачи. У градиентного спуска такого свойства нет!

110. Проекция.

💡 Проекция точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2$$

111. Достаточное условие существования проекции точки на множество.

💡 Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, тогда проекция на множество S существует для любой точки.

112. Достаточное условие единственности проекции точки на множество.

💡 Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, тогда проекция на множество S единственна для каждой точки.

113. Метод проекции градиента.

💡 Рассматривается задача $f(x) \rightarrow \min_{x \in S}$, где $S \subseteq \mathbb{R}^n$. Метод проекции градиента — это метод оптимизации с проекцией на бюджетное множество S :

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)),$$

где α_k — learning rate.

114. Критерий проекции точки на выпуклое множество (Неравенство Бурбаки-Чейни-Гольдштейна).

💡 Проекция $\text{proj}_S(x)$ точки x на выпуклое множество S удовлетворяет:

$$\langle x - \text{proj}_S(x), y - \text{proj}_S(x) \rangle \leq 0 \quad \forall y \in S.$$

115. Проекция как нерастягивающий оператор.


💡 Проекция на выпуклое множество S является нерастягивающим оператором:

$$\|\text{proj}_S(x) - \text{proj}_S(y)\| \leq \|x - y\| \quad \forall x, y.$$

116. Метод Франк-Вульфа.

💡 Рассматриваем задачу $f(x) \rightarrow \min_{x \in S}$. Метод Франк-Вульфа имеет вид:

$$y_k = \arg \min_{x \in S} f_{x_k}^I(x) = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$$
$$x_{k+1} = \gamma_k x_k + (1 - \gamma_k) y_k$$



где γ_k - гиперпараметр.

117. Характер сходимости метода проекции градиента для гладких выпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 Для гладких выпуклых функций метод проекции градиента имеет сходимость порядка $\mathcal{O}(\frac{1}{k})$, где k — число итераций. То есть сходимость такая же, как и для безусловной задачи, но стоимость итерации может быть выше из-за проекции.

118. Характер сходимости метода проекции градиента для гладких сильно выпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 Для гладких сильно выпуклых функций метод проекции градиента имеет линейную сходимость порядка $\mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$, где k — число итераций. То есть сходимость такая же, как и для безусловной задачи, но стоимость итерации может быть выше из-за проекции.

119. Характер сходимости метода Франк-Вульфа для гладких выпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 Метод Франк-Вульфа для гладких выпуклых функций имеет сходимость порядка $\mathcal{O}(\frac{1}{k})$, где k — число итераций.

120. Характер сходимости метода Франк-Вульфа для гладких сильно выпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 Для гладких сильно выпуклых функций метод Франк-Вульфа имеет сходимость порядка $\mathcal{O}(\frac{1}{k})$, где k — число итераций.

121. Нижние оценки для условной оптимизации с помощью оракула линейной минимизации для сильно выпуклых гладких функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 $f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$

122. Привести пример выпуклой негладкой задачи линейных наименьших квадратов (возможно, с регуляризацией).

💡 Рассмотрим задачу минимизации функции:

$$f(x) = \|Ax - b\|_2^2 + \lambda \|x\|_1,$$

где $A \in \mathbb{R}^{n \times n}$, $\lambda > 0$. Эта функция выпукла, но негладка из-за наличия ℓ_1 -регуляризации.

123. Субградиент. Субдифференциал.

💡 Субградиент функции f в точке x — это вектор g , удовлетворяющий условию:

$$f(y) \geq f(x) + g^T(y - x), \quad \forall y.$$

Множество всех субградиентов в точке x называется субдифференциалом и обозначается как $\partial f(x)$.




Рисунок 15: Субдифференциал функции ReLU.

124. Как считать субдифференциал поточечного максимума выпуклых функций.

💡 Пусть $f_i(x)$ - выпуклые функции на открытом выпуклом множестве $S \subseteq \mathbb{R}^n$, $x_0 \in S$, и поточечный максимум определяется как $f(x) = \max_i f_i(x)$. Тогда:

$$\partial_S f(x_0) = \text{conv} \left\{ \bigcup_{i \in I(x_0)} \partial_S f_i(x_0) \right\}, \quad I(x) = \{i \in [1 : m] : f_i(x) = f(x)\}$$

125. Субградиентный метод.

- 💡 Субградиентный метод используется для минимизации выпуклых функций, которые могут быть негладкими. Итерационная формула метода:

$$x_{k+1} = x_k - \alpha_k g_k,$$

где $g_k \in \partial f(x_k)$ — субградиент функции f в точке x_k , α_k — шаг метода на k -й итерации.

126. Характер сходимости субградиентного метода для негладких выпуклых Липшицевых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 $f_k^{\text{best}} - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$

127. Какому условию должна удовлетворять стратегия выбора шага, чтобы субградиентный метод сходил для выпуклых Липшицевых функций?

💡 $\sum_{i=1}^k \alpha_i = \infty, \quad \sum_{i=1}^k \alpha_i^2 < \infty$

128. Характер сходимости субградиентного метода для негладких сильно выпуклых Липшицевых функций в терминах $\mathcal{O}$ от числа итераций метода. Стратегия выбора шага.

💡 $f_k^{\text{best}} - f^* \sim \mathcal{O}\left(\frac{1}{k}\right), \alpha_k = \frac{2}{\mu(k+1)}$

129. Нижние оценки для негладкой выпуклой оптимизации с помощью методов первого порядка в терминах $\mathcal{O}$ от числа итераций метода.

💡 $f_k^{\text{best}} - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$

130. Нижние оценки для негладкой сильно выпуклой оптимизации с помощью методов первого порядка в терминах $\mathcal{O}$ от числа итераций метода.

💡 $f_k^{\text{best}} - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$

131. Проксимальный оператор.

💡 $\text{prox}_f(x_k) = \arg \min_{x \in \mathbb{R}^n} [f(x) + \frac{1}{2} \|x - x_k\|_2^2]$

132. Оператор проекции как частный случай проксимального оператора.



$$\text{proj}_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2$$

Введём индикаторную функцию:

$$\mathbb{I}_S(x) = \begin{cases} 0, & \text{if } x \in S, \\ \infty, & \text{else.} \end{cases}$$

Перепишем оператор:

$$\text{proj}_S(y) = \arg \min_{x \in S} \left[\frac{1}{2} \|x - y\|_2^2 + \mathbb{I}_S(x) \right]$$

И, для сравнения, вспомним $\text{prox}_r(x_k) = \arg \min_{x \in \mathbb{R}^n} \left[\frac{1}{2} \|x - x_k\|_2^2 + r(x) \right]$.

133. Характер сходимости проксимального градиентного метода для гладких выпуклых функций f в терминах $\mathcal{O}$ от числа итераций метода.



Рассматривается задача: $\varphi(x) \rightarrow \min_{x \in \mathbb{R}^n}$, где $\varphi(x) = f(x) + r(x)$, $f(x)$ - гладкая выпуклая, $r(x)$ - негладкая выпуклая, проксимально дружественная.

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

Сходится за $\mathcal{O}\left(\frac{1}{k}\right)$.

134. Характер сходимости проксимального градиентного метода для гладких сильно выпуклых функций f в терминах $\mathcal{O}$ от числа итераций метода.



Рассматривается задача: $\varphi(x) \rightarrow \min_{x \in \mathbb{R}^n}$, где $\varphi(x) = f(x) + r(x)$, $f(x)$ - гладкая выпуклая, $r(x)$ - негладкая выпуклая, проксимально дружественная.

$$\|x_k - x^*\|^2 \sim \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$$

где μ - константа сильной выпуклости функции f , L - константа гладкости функции f .

135. Аналитическое выражение для $\text{prox}_{\lambda \|x\|_1}$.



$$\begin{aligned} r(x) &= \lambda \|x\|_1, \quad \lambda > 0 \\ [\text{prox}_r(x)]_i &= [|x_i - \lambda|_+] \cdot \text{sign}(x_i) \end{aligned}$$

136. Аналитическое выражение для $\text{prox}_{\frac{\mu}{2} \|x\|_2^2}$.



$$r(x) = \frac{\mu}{2} \|x\|_2^2$$

$$\text{prox}_r(x) = \frac{x}{1 + \mu}$$

137. Проксимальный оператор как нестягивающий оператор.



Проксимальный оператор $\text{prox}_r(x)$ строго нестягивающий (FNE - firmly non-expansive):

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq \langle \text{prox}_r(x) - \text{prox}_r(y), x - y \rangle$$

и нестягивающий:

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2$$

138. Характер сходимости ускоренного проксимального градиентного метода для гладких выпуклых функций f в терминах $\mathcal{O}$ от числа итераций метода.



$\varphi(x) = f(x) + r(x)$, $f(x)$ - выпуклая, L -гладкая, $r(x)$ - выпуклая и определен $\text{prox}_{\alpha r}(x_k) \Rightarrow$
 $\varphi(x_k) - \varphi^* \leq \frac{L\|x_0 - x^*\|^2}{2k^2} \sim \mathcal{O}\left(\frac{1}{k^2}\right)$

139. Метод стохастического градиентного спуска.



Решаемая задача: $f(x) \rightarrow \min_{x \in \mathbb{R}^p}$, где $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$

$$\text{SGD: } x_{k+1} = x_k - \alpha_k \nabla f_{i_k}(x),$$


где i_k - случайно выбранный индекс. Если $\mathbb{P}(i_k = i) = \frac{1}{n}$, то $\mathbb{E}[\nabla f_{i_k}(x)] = \nabla f(x)$

140. Идея мини-батча для метода стохастического градиентного спуска. Эпоха.

- 💡 Разделим данные размера N на k мини-батчей (выборок) размера B_k , на каждой итерации посчитаем градиент мини-батча с использованием параллелизма. За $\frac{N}{k}$ итераций пройдемся по всей выборке. **Эпоха** - набор k итераций с батчем размера $B_k = \frac{N}{k}$.

$$x_{k+1} = x_k - \frac{1}{|B_k|} \sum_{i \in B_k} \text{— шаг мини-батча.}$$

С увеличением размера мини-батча время на эпоху уменьшается до тех пор, пока нам хватает памяти (в случае наличия параллелизма).



141. Характер сходимости стохастического градиентного спуска для гладких выпуклых функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 f - гладкая и выпуклая $\Rightarrow \mathcal{O}\left(\frac{1}{\varepsilon^2}\right), \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$

142. Характер сходимости стохастического градиентного спуска для гладких PL-функций в терминах $\mathcal{O}$ от числа итераций метода.

💡 $f \in \text{PL} \Rightarrow \mathcal{O}\left(\frac{1}{k}\right), \mathcal{O}\left(\frac{1}{\varepsilon}\right)$

143. Характер работы стохастического градиентного спуска с постоянным шагом для гладких PL-функций.

💡 Пусть $\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$ при использовании стохастического градиентного спуска с постоянным шагом α

$$x_{k+1} = x_k - \alpha \nabla f_{i_k}(x_k)$$

имеем следующую оценку $\mathbb{E}[f(x_{k+1}) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}$. Характер сходимости - линейный до некоторого шара несходимости, в котором будут происходить осцилляции и сходимости не будет.

144. Основная идея методов уменьшения дисперсии.

💡 Рассматриваем случайную величину X . Хотим уменьшить у неё дисперсию. Пусть Y - тоже случайная величина с известным мат. ожиданием. Рассмотрим новую с.в $Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - $\alpha = 1$: нет смещения мат. ожидания
 - $\alpha < 1$: потенциальное смещение (но уменьшение дисперсии).
- Полезно, если Y коррелирует с X .

145. Метод SVRG.

- 💡
- Пусть $X = \nabla f_{i_k}(x_{m-1})$ - стох. градиент, а $Y = \nabla f_{i_k}(\tilde{x})$, с $\alpha = 1$ и $\tilde{x}$ хранятся в памяти.
 - $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$ полный градиент в $\tilde{x}$;
 - $X - Y = \nabla f_{i_k}(x^{(m-1)}) - \nabla f_{i_k}(\tilde{x})$

Получаем алгоритм:

- **Initialize:** $\tilde{x} \in \mathbb{R}^d$
- **For** $i_{epoch} = 1$ **to** # of epochs
- Compute all gradients $\nabla f_i(\tilde{x})$; store $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
- Initialize $x_0 = \tilde{x}$
- **For** $t = 1$ **to** length of epochs (m)
 - Pick $i_t \in \{1, \dots, n\}$ uniformly at random
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
- Update $\tilde{x} = x_m$

146. Метод SAG.

💡 Задача: $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$

1. Initialize $x^{(0)}$ and $g_i^{(0)} = \nabla f_i(x^{(0)})$
2. At steps $k = 1, 2, 3, \dots$ pick random $i_k \in \{1, \dots, n\}$
3. $g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)})$
4. Set all other $g_i^{(k)} = g_i^{(k-1)}, i \neq i_k$
5. Update: $g^{(k)} = g^{(k-1)} + \frac{1}{n}(g_{i_k}^{(k)} - g_{i_k}^{(k-1)}) = \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$
6. $x^{(k)} = x^{(k-1)} - \alpha g^{(k)}$

PS: стоимость итерации как в обычном SGD, но платим за это памятью.

Сходимость в выпуклом случае: $f(x_{\text{mean}}^{(k)}) - f^* \leq \frac{48n|f(x^{(0)}) - f^*| + 128L\|x^{(0)} - x^*\|^2}{k} = O(\frac{1}{k})$

Скорость в сильно выпуклом случае с параметром μ :

$$\mathbb{E}[f(x^{(k)}) - f^*] \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right) = O(\gamma^k)$$

147. Метод Adagrad.

💡 Задача: $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$. Пусть $g^{(k)} = \nabla f_{i_k}(x^{(k-1)})$, и обновляем for $j = 1, \dots, p$:

$$v_j^{(k)} = v_j^{(k-1)} + (g_j^{(k)})^2$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \frac{g_j^{(k)}}{\sqrt{v_j^{(k)} + \varepsilon}}$$

Постоянная ε обычно устанавливается равным 10^{-6} чтобы гарантировать, что мы не будем иметь проблемы от деления на ноль или чрезмерно больших размеров шага.

148. Метод AdamW.

💡 Решает проблему с ℓ_2 регуляризацией в адаптивных оптимизаторах, таких как Adam. Стандартная ℓ_2 регуляризация добавляет $\lambda\|x\|^2$ к функции потерь, что приводит к градиентному члену λx . В Adam этот член масштабируется вместе с адаптивным шагом обучения $(\sqrt{\hat{v}_j} + \epsilon)$, связывая демпфирование с градиентами.

AdamW отделяет демпфирование от шага адаптации градиента.

$$m_j^{(k)} = \beta_1 m_j^{(k-1)} + (1 - \beta_1) g_j^{(k)}$$

$$v_j^{(k)} = \beta_2 v_j^{(k-1)} + (1 - \beta_2) (g_j^{(k)})^2$$

$$\hat{m}_j = \frac{m_j^{(k)}}{1 - \beta_1^k}, \quad \hat{v}_j = \frac{v_j^{(k)}}{1 - \beta_2^k}$$

$$x_j^{(k)} = x_j^{(k-1)} - \alpha \left(\frac{\hat{m}_j}{\sqrt{\hat{v}_j} + \epsilon} + \lambda x_j^{(k-1)} \right)$$

149. Метод Shampoo.



- Вычисляем градиент G_k .
- Обновляем статистики $L_k = \beta L_{k-1} + (1 - \beta)G_k G_k^T$ и $R_k = \beta R_{k-1} + (1 - \beta)G_k^T G_k$.
- Вычисляем предобуславливатели $P_L = L_k^{-1/4}$ и $P_R = R_k^{-1/4}$. (Обратный корень матрицы)
- Обновляем: $W_{k+1} = W_k - \alpha P_L G_k P_R$.

150. Метод Muon.



$$W_{t+1} = W_t - \eta UV^T,$$

где $G = U \Sigma V^T$ - сингулярное разложение матрицы градиентов соответствующей текущему слою.

151. Как сравниваются методы в AlgoPerf Benchmark.




Для бенчмарка формулируется несколько различных прикладных задач и моделей. Для каждой из них задаётся необходимый уровень целевой функции, который должен быть достигнут за отведённое время.

Для каждой задачи выбирается лучший метод и время его работы обозначается за t_{best} . Для всех методов строят график процента решенных задач в зависимости от коэффициента τ , который показывает во сколько раз больше времени потрачено по сравнению с лучшим методом на данной задаче $t = \tau t_{best}$.

Submission	Line	Score
PYTORCH DISTRIBUTED SHAMPOO		0.7784
SCHEDULE FREE ADAMW		0.7077
GENERALIZED ADAM		0.6383
CYCLIC LR		0.6301
NADAMP		0.5909
BASLINE		0.5707
AMOS		0.4918
CASPR ADAPTIVE		0.4722
LAWA QUEUE		0.3699
LAWA EMA		0.3384
SCHEDULE FREE PRODIGY		0

(a) External tuning leaderboard



(b) External tuning performance profiles

152. Идея проекции функции потерь нейронной сети на прямую, плоскость.

💡 Пусть $L(w)$ - функция от $w \in \mathbb{R}^n$. Введем проекцию на линию:

$$L(\alpha) = L(w_0 + \alpha w_1)$$

для некоторого $w_1 \in \mathbb{R}^n$. Аналогично можно ввести проекцию на плоскость


$$L(\alpha, \beta) = L(w_0 + \alpha w_1 + \beta w_2)$$

для некоторых $w_1, w_2 \in \mathbb{R}^n$.

- Два случайных вектора большой размерности с высокой вероятностью ортогональны друг другу.
- Если проекция функции невыпукла, то и исходная функция невыпукла. Таким образом можно заглянуть на устройство функции от многих переменных.

153. Grokking.

💡 Grokking при обучении нейронных сетей — это явление, когда модель после продолжительного обучения сначала демонстрирует плохую обобщающую способность на новых данных, несмотря на хорошее качество на обучающем наборе. Затем, после дальнейшего обучения, модель неожиданно начинает показывать значительно лучшую производительность и на тестовых данных. Это подразумевает, что модель в конечном итоге находит более глубокие и универсальные закономерности, которые позволяют ей лучше обобщать на неизвестные данные.



154. Double Descent.

💡 Double descent — это явление, наблюдаемое при обучении нейронных сетей, когда увеличение количества параметров модели сначала приводит к снижению ошибки на обучающем и тестовом наборах (классическое поведение bias-variance tradeoff), затем происходит резкое увеличение ошибки (первая точка перегиба, связанная с переобучением), после чего, с дальнейшим увеличением количества параметров, ошибка снова начинает уменьшаться, формируя вторую “волну” улучшения. Это поведение отличается от традиционной U-образной кривой, и его понимание важно для эффективной настройки гиперпараметров и выбора архитектуры модели.




Рисунок 16: Иллюстрация зависимости обобщающей способности модели от размера.


155. Взрыв/Затухание градиентов при обучении глубоких нейронных сетей.

💡 При обучении глубоких нейронных сетей часто возникают проблемы взрыва и затухания градиентов, что приводит к медленной или нестабильной сходимости модели. Эти явления можно описать с помощью производной функции ошибки L по весам сети W . Пусть L - функция потерь, а $\frac{\partial L}{\partial W}$ - градиенты, используемые для обновления весов. Когда сеть имеет много слоев, градиенты вычисляются как произведение матриц Якоби каждого слоя: $\frac{\partial L}{\partial W} = \frac{\partial L}{\partial z^{(n)}} \cdot \frac{\partial z^{(n)}}{\partial z^{(n-1)}} \cdots \frac{\partial z^{(2)}}{\partial z^{(1)}} \cdot \frac{\partial z^{(1)}}{\partial W}$, где $z^{(i)}$ - активации i -го слоя. Если значения производных $\frac{\partial z^{(i+1)}}{\partial z^{(i)}}$ в среднем больше единицы, градиенты начинают экспоненциально увеличиваться при обратном распространении, вызывая взрыв градиентов. Напротив, если значения производных меньше единицы, градиенты экспоненциально уменьшаются, что приводит к их затуханию.

156. Идея gradient checkpointing.

💡 Gradient checkpointing — это техника, которая позволяет значительно снизить потребление памяти при обучении глубоких нейронных сетей за счет стратегического пересчета промежуточных активаций во время обратного распространения ошибки. В стандартном процессе обучения с использованием обратного распространения ошибка вычисляется для каждого слоя и промежуточные активации сохраняются в памяти, что требует $O(N)$ памяти, где N — количество слоев в сети.

При gradient checkpointing вместо сохранения активаций для всех слоев, мы сохраняем их только для некоторых стратегически выбранных слоев, называемых чекпоинтами. Активации для остальных слоев пересчитываются на этапе обратного распространения, что снижает общее потребление памяти. Если мы сохраняем активации через каждые k слоев, то потребление памяти уменьшается до $O(\frac{N}{k})$. Однако, это приводит к дополнительным вычислительным затратам, так как активации некоторых слоев пересчитываются несколько раз.



157. Идея аккумуляции градиентов.

💡 Аккумуляция градиентов — это метод, используемый для эффективного обучения больших нейросетевых моделей, когда ограничен объем доступной видеопамяти. Вместо обновления весов модели после каждого батча данных, как это происходит в стандартном стохастическом градиентном спуске (SGD), градиенты накапливаются в течение нескольких батчей. Затем обновление весов происходит только после накопления градиентов от нескольких батчей, эквивалентных одному большому батчу. Этот подход позволяет использовать меньший объем памяти, так как не требуется хранить большие батчи данных в видеопамяти, при этом достигается сходный с большим батчем эффект на обновление весов, что способствует более стабильному и эффективному обучению модели.

158. Зачем увеличивать батч при обучении больших нейросетевых моделей. Warmup.

💡 Если увеличивать размер батча, то, при наличии параллелизма, время прохождения эпохи уменьшается. Эмпирическое правило: когда размер минибатча увеличился в k раз, learning rate также необходимо увеличить в k раз (linear scaling rule). Для адаптивных методов эмпирически используется шкалирование базового learning rate в $\sqrt{k}$ раз (square root scaling rule).

Warmup — это техника, применяемая к процессу обучения моделей, чтобы стабилизировать и улучшить обучение на ранних этапах. В процессе Warmup начальное значение скорости обучения постепенно увеличивается от низкого значения до целевого значения в течение нескольких первых эпох или шагов. Эта техника помогает избежать проблем, связанных с нестабильностью градиентов и резкими изменениями параметров модели в самом начале обучения.





Рисунок 17: При увеличении размера батча время на эпоху уменьшается до тех пор, пока нам хватает памяти (в случае наличия параллелизма).


159. Идея cooldown фазы для построения расписания learning rate. В чём преимущество по сравнению с cosine scheduler?

- 💡 Подход к расписанию learning rate, заключающийся в постепенном уменьшении learning rate в конце обучения. Позволяет избежать знания длительности обучения, в отличие от cosine scheduler.




160. Data Parallel обучение на нескольких видеокартах.

- 💡
1. Сервер параметров отправляет полную копию модели на каждое устройство
 2. Каждое устройство выполняет прямой и обратный проходы
 3. Сервер параметров собирает градиенты
 4. Сервер параметров обновляет модель




161. GPipe Pipeline параллелизм.

- 💡 GPipe разделяет модель на этапы, каждый из которых обрабатывается последовательно. Микро-батчи проходят через пайплайн, что позволяет перекрывать вычисления и коммуникации.



162. PipeDream Pipeline параллелизм.



163. Дообучение больших моделей с помощью LoRA адаптеров.

💡 LoRA предполагает дообучать модель в виде поиска добавки к весам малого ранга

$$W_{\text{new}} = W + \Delta W$$

где $\Delta W = AB^T$, причем A и B являются матрицами низкого ранга. Это уменьшает вычислительные затраты, сохраняя производительность модели.

- A инициализируется как обычно, тогда как B инициализируется нулями, чтобы начать с тождественного отображения
- r обычно выбирается в диапазоне от 2 до 64
- Обычно применяется к модулям внимания

$$h = W_{\text{new}}x = Wx + \Delta Wx = Wx + AB^Tx$$




Рисунок 18: Схема работы

164. Сколько токенов в обучающей выборке приходилось на модель Chinchilla на один обучаемый параметр модели?

💡 20. Размер модели 70B, количество токенов 1.4Т.

165. Метод двойственного градиентного подъема.

💡 Рассматривается задача:

$$f(x) \rightarrow \min_{Ax=b}.$$

Двойственная задача:

$$-f^*(-A^T u) - b^T u \rightarrow \max_u,$$

где $f^*(y) = \max_x [y^T x - f(x)]$ - сопряженная функция. Определим $g(u) = -f^*(-A^T u) - b^T u$, тогда $\partial g(u) = A \partial f^*(-A^T u) - b$. Перепишем это в виде $\partial g(u) = Ax - b$, где $x \in \arg \min_z [f(z) + u^T Az]$. Тогда определим метод двойственного градиентного подъема:

$$x_k \in \arg \min_x [f(x) + (u_{k-1})^T Ax]$$

$$u_k = u_{k-1} + \alpha_k (Ax_k - b).$$

166. Связь константы сильной выпуклости f и гладкости f^* .

💡 Пусть f - замкнутая и выпуклая. Тогда f - сильно выпуклая с константой выпуклости $\mu \Leftrightarrow \nabla f^*$ - липшицев с параметром $\frac{1}{\mu}$.

167. Идея dual decomposition.

💡 Рассматриваем задачу $\sum_{i=1}^B f_i(x_i) \rightarrow \min_{Ax=b}$. Здесь $x = (x_1, \dots, x_B)^T \in \mathbb{R}^n$ разделены на B блоков переменных, каждый $x_i \in \mathbb{R}^{n_i}$. Разделим аналогично матрицу A : $A = [A_1, \dots, A_B]$, где $A_i \in \mathbb{R}^{m \times n_i}$. Тогда

$$x^{\text{new}} \in \arg \min_x \left(\sum_{i=1}^B f_i(x_i) + u^T Ax \right) \Rightarrow x_i^{\text{new}} \in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = \overline{1, B}$$

Тогда метод двойственного подъема запишется следующим образом:

$$x_i^k \in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = \overline{1, B}$$

$$u^k = u^{k-1} + \alpha_k \left(\sum_{i=1}^B A_i x_i^k - b \right).$$

168. Метод двойственного градиентного подъема для линейных ограничений-неравенств.

💡 Рассматриваем задачу $\sum_{i=1}^B f_i(x_i) \rightarrow \min_{\sum_{i=1}^B A_i x_i \preceq b}$.

$$x_i^k \in \arg \min_{x_i} [f_i(x_i) + (u^{k-1})^T A_i x_i], \quad i = \overline{1, B}$$

$$u^k = \left(u^{k-1} + \alpha_k \left[\sum_{i=1}^B A_i x_i^k - b \right] \right)_+,$$

где $(u)_+$ обозначает $(u_+)_i = \max\{0, u_i\}, i = \overline{0, m}$.

169. Метод модифицированной функции Лагранжа.

💡 Рассматриваем задачу $f(x) + \frac{\rho}{2} \|Ax - b\|^2 \rightarrow \min_{Ax=b}$, где $\rho > 0$ - параметр. Тогда метод двойственного градиентного подъема имеет вид:

$$x_k = \arg \min_x \left[f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2 \right]$$

$$u_k = u_{k-1} + \rho(Ax_k - b).$$

В этом случае имеет место следующее:

$$L = f(x) + u^T(Ax - b) + \frac{\rho}{2} \|Ax - b\|^2$$

$$x_k = \arg \min_x \left[f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2 \right]$$

$$0 \in \partial f(x_k) + A^T(u_{k-1} + \rho(Ax_k - b))$$

$$0 \in \partial f(x_k) + A^T u_k.$$

170. Метод ADMM.

💡 Рассматриваем задачу

$$\min_{x,z} f(x) + g(z)$$

$$\text{s.t. } Ax + Bz = c$$

После добавления штрафа за выход из бюджетного множества имеем $f(x) + g(z) + \frac{\rho}{2} \|Ax + Bz - c\|^2 \rightarrow \min_{Ax+Bz=c}$, где $\rho > 0$ - параметр. Тогда функция Лагранжа имеет вид:

$$L_\rho(x, z, u) = f(x) + g(z) + u^T(Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2.$$

И шаг ADMM записывается как:

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

$$u_k = u_{k-1} + \rho(Ax_k + Bz_k - c).$$

Теоремы с доказательствами

1. Тест корней для определения скорости сходимости последовательности.

i Пусть $(r_k)_{k=m}^{\infty}$ — последовательность неотрицательных чисел, сходящаяся к нулю, и пусть $\alpha := \limsup_{k \rightarrow \infty} r_k^{1/k}$. (Заметим, что $\alpha \geq 0$.)

- (a) Если $0 \leq \alpha < 1$, то $(r_k)_{k=m}^{\infty}$ сходится линейно с константой α .
- (b) В частности, если $\alpha = 0$, то $(r_k)_{k=m}^{\infty}$ сходится сверхлинейно.
- (c) Если $\alpha = 1$, то $(r_k)_{k=m}^{\infty}$ сходится сублинейно.
- (d) Случай $\alpha > 1$ невозможен.

Доказательство.

- Покажем, что если $(r_k)_{k=m}^{\infty}$ сходится линейно с константой $0 \leq \beta < 1$, то $\alpha \leq \beta$. Действительно, по определению константы линейной сходимости, для любого $\varepsilon > 0$ такого, что $\beta + \varepsilon < 1$, существует $C > 0$ такое, что $r_k \leq C(\beta + \varepsilon)^k$ для всех $k \geq m$. Из этого следует, что $r_k^{1/k} \leq C^{1/k}(\beta + \varepsilon)$ для всех $k \geq m$. Переходя к пределу при $k \rightarrow \infty$ и используя $C^{1/k} \rightarrow 1$, получаем $\alpha \leq \beta + \varepsilon$. Учитывая произвольность ε , получаем $\alpha \leq \beta$.
- Таким образом, в случае $\alpha = 1$ последовательность $(r_k)_{k=m}^{\infty}$ не может иметь линейной сходимости в соответствии с приведенным выше результатом (доказано от противного). Тем не менее, $(r_k)_{k=m}^{\infty}$ сходится к нулю, поэтому она должна сходиться сублинейно.
- Теперь рассмотрим случай $0 \leq \alpha < 1$. Пусть $\varepsilon > 0$ — произвольное число такое, что $\alpha + \varepsilon < 1$. Согласно свойствам $\limsup$, существует $N \geq m$ такое, что $r_k^{1/k} \leq \alpha + \varepsilon$ для всех $k \geq N$. Следовательно, $r_k \leq (\alpha + \varepsilon)^k$ для всех $k \geq N$. Таким образом, $(r_k)_{k=m}^{\infty}$ сходится линейно с параметром $\alpha + \varepsilon$ (не важно, что неравенство выполняется только начиная с числа N). Учитывая произвольность ε , это означает, что константа линейной сходимости $(r_k)_{k=m}^{\infty}$ не превышает α . Поскольку, как показано выше, константа линейной сходимости не может быть меньше α , это означает, что константа линейной сходимости $(r_k)_{k=m}^{\infty}$ точно равна α .
- Наконец, покажем, что случай $\alpha > 1$ невозможен. Действительно, предположим, что $\alpha > 1$. Тогда из определения $\limsup$ следует, что для любого $N \geq m$ существует $k \geq N$ такое, что $r_k^{1/k} \geq 1$, и, в частности, $r_k \geq 1$. Но это означает, что r_k имеет подпоследовательность, ограниченную от нуля. Следовательно, $(r_k)_{k=m}^{\infty}$ не может сходиться к нулю, что противоречит условию.

2. Метод дихотомии и золотого сечения для унимодальных функций. Скорость сходимости.

i Методы локализации решения для скалярной минимизации. Сходятся линейно.

Метод дихотомии

Решаем следующую задачу:

$$f(x) \rightarrow \min_{x \in [a,b]}$$

где $f(x)$ — унимодальная функция.

Мы хотим на каждом шаге вдвое сокращать область, в которой ищем минимум. Для этого будем пользоваться основным свойством унимодальных функций:

$$\forall a \leq x_1 < x_2 \leq b :$$

$$f(x_1) \leq f(x_2) \Rightarrow x_* \in [a, x_2]$$

$$f(x_1) \geq f(x_2) \Rightarrow x_* \in [x_1, b]$$

где x_* — точка, в которой достигается минимум

Алгоритм:




Рисунок 19: Алгоритм дихотомии

Можно заметить, что на каждой итерации требуется не более 2-х вычислений значения функции.

Сходимость метода дихотомии

Длина отрезка на k -ой итерации:

$$\Delta_k = b_k - a_k = \frac{1}{2^k}(b - a)$$

Если будем выбирать середину отрезка как выход k -ой итерации:

$$|x_k - x_*| \leq \frac{\Delta_k}{2}$$

Подставим полученное ранее выражение для длины отрезка:

$$|x_k - x_*| \leq \frac{1}{2^{k+1}}(b - a)$$

$$|x_k - x_*| \leq (0.5)^{k+1}(b - a)$$

Получили выражение для сходимости по итерациям. Отсюда также можно выразить необходимое количество итераций для достижения точности ε :

$$K = \left\lceil \log_2 \frac{b - a}{\varepsilon} - 1 \right\rceil$$

Теперь получим выражение для сходимости по количеству вычислений значения функции. Знаем, что на каждой итерации вычисляем значение не более 2-х раз, значит количество вычислений значения функции возьмём $N = 2k$:

$$|x_k - x_*| \leq (0.5)^{\frac{N}{2}+1}(b - a)$$

$$|x_k - x_*| \leq (0.707)^N \frac{b - a}{2}$$

Метод золотого сечения

Идея такая же, как и в методе дихотомии, но хотим уменьшить количество вычислений значения функции. Для этого будем вычислять значения в точках золотого сечения. Так на каждой итерации нам нужно будет вычислять значение только в одной точке, так как для нового отрезка в одной из точек золотого сечения значение будет уже посчитано:




Рисунок 20: Золотое сечение

Алгоритм:

```
def golden_search(f, a, b, epsilon):
    tau = (sqrt(5) + 1) / 2
    y = a + (b - a) / tau**2
    z = a + (b - a) / tau
    while b - a > epsilon:
        if f(y) <= f(z):
            b = z
            z = y
            y = a + (b - a) / tau**2
        else:
            a = y
            y = z
            z = a + (b - a) / tau
    return (a + b) / 2
```

Сходимость метода золотого сечения

На каждой итерации длина отрезка будет уменьшаться в $\tau = \frac{\sqrt{5}+1}{2}$ раз. Тогда оценка сходимости (и по итерациям, и по вычислениям значений функции):

$$|x_k - x_*| \leq \frac{b_k - a_k}{2} = \left(\frac{1}{\tau}\right)^N \frac{b - a}{2} \approx 0.618^k \frac{b - a}{2}$$

Получили сходимость по итерациям хуже, чем у дихотомии, так как отрезки уменьшаются слабее на каждой итерации. Но по количеству вычислений значения функции сходимость у метода золотого сечения быстрее.

3. Автоматическое дифференцирование. Вычислительный граф. Forward/ Backward mode (в этом вопросе нет доказательств, но необходимо подробно описать алгоритмы).

i Для функции $L(w_1, w_2, \dots, w_d)$ вычислительный граф представляет собой ориентированный ациклический граф с двумя типами вершин: $w_1, w_2, \dots, w_d$ и $f_1, f_2, \dots$. Здесь $w_1, w_2, \dots, w_d$ обозначают входные переменные, а $v_1, v_2, \dots$ обозначают промежуточные функции. В $w_1, w_2, \dots, w_d$ нет входящих ребер, а входящие ребра в $v_1, v_2, \dots$ обозначают значения, подающиеся на вход функциям. Также есть одна единственная вершина, соответствующая итоговому значению L , из которой не выходит ребер. Это описание характерно для функции, используемой в обучении нейросети, где может быть множество вершин-стоков $L_1, L_2, \dots$.




Рисунок 21: Вычислительный граф

Для вычисления $\frac{\partial L}{\partial w_k}$ для всех k рассмотрим две процедуры.

Forward mode

Для каждой $w_1, w_2, \dots, w_d$ выполняется следующее: для всех i вычисляются $\dot{v}_i = \frac{\partial v_i}{\partial w_k}$. Для этого выполняется:

- Вычисляется v_i как функция от её родителей (входов) $x_1, \dots, x_{t_i}$:

$$v_i = v_i(x_1, \dots, x_{t_i})$$

- Вычисляется производная $\dot{v}_i$ с использованием правила производной сложной функции:

$$\dot{v}_i = \sum_{j=1}^{t_i} \frac{\partial v_i}{\partial x_j} \frac{\partial x_j}{\partial w_k}$$




Рисунок 22: Forward mode

Заметим, что для вычисления $\frac{\partial L}{\partial w_k}$ требуется $O(T)$ операций умножения и сложения градиентов, где T - число элементов в вычислительном графе. Итого $O(dT)$.

Backward mode

Forward pass

- Вычисляется v_i как функция от её родителей (входов) $x_1, \dots, x_{t_i}$:

$$v_i = v_i(x_1, \dots, x_{t_i})$$

Backward pass

Обрабатывая вершины в обратном порядке топологического упорядочения:

- Вычисляется производная $\dot{v}_i$, используя правило дифференцирования сложной функции в обратном порядке и информацию от всех его потомков (выходов) $(x_1, \dots, x_{t_i})$, используя предподсчитанные значения на forward pass:

$$\dot{v}_i = \frac{\partial L}{\partial \mathbf{v}_i} = \sum_{j=1}^{t_i} \frac{\partial L}{\partial x_j} \frac{\partial x_j}{\partial \mathbf{v}_i}$$





Рисунок 23: Backward mode

Backward mode быстрее для единственного выхода L . Работает аналогично за линейное время.



4. Выпуклость надграфика как критерий выпуклости функции.

i Чтобы функция $f(x)$, определенная на выпуклом множестве X , была выпуклой на X , необходимо и достаточно чтобы надграфик f был выпуклым множеством.

Для функции $f(x)$, определенной на $S \subseteq \mathbb{R}^n$, множество:

$$\text{epi } f = \{[x, \mu] \in S \times \mathbb{R} : f(x) \leq \mu\}$$

называется **надграфиком** функции $f(x)$ (здесь $\mu \in \mathbb{R}, x \in S$).

Необходимость

Предположим, что $f(x)$ выпукла на X . Возьмем две произвольные точки $[x_1, \mu_1] \in \text{epi } f$ и $[x_2, \mu_2] \in \text{epi } f$. Также возьмем $0 \leq \lambda \leq 1$ и обозначим $x_\lambda = \lambda x_1 + (1 - \lambda)x_2, \mu_\lambda = \lambda \mu_1 + (1 - \lambda)\mu_2$. Тогда,

$$\lambda \begin{bmatrix} x_1 \\ \mu_1 \end{bmatrix} + (1 - \lambda) \begin{bmatrix} x_2 \\ \mu_2 \end{bmatrix} = \begin{bmatrix} x_\lambda \\ \mu_\lambda \end{bmatrix}.$$

Из выпуклости X следует, что $x_\lambda \in X$. Более того, так как $f(x)$ – выпуклая функция, то

$$f(x_\lambda) \leq \lambda f(x_1) + (1 - \lambda)f(x_2) \leq \lambda \mu_1 + (1 - \lambda)\mu_2 = \mu_\lambda$$

Из неравенства выше по определению надграфика следует, что $\begin{bmatrix} x_\lambda \\ \mu_\lambda \end{bmatrix} \in \text{epi } f$. Следовательно, надграфик f – выпуклое множество.

Достаточность

Предположим, что надграфик f , $\text{epi } f$, выпуклое множество. Тогда, исходя из того что $[x_1, \mu_1] \in \text{epi } f$ и $[x_2, \mu_2] \in \text{epi } f$, получаем

$$\begin{bmatrix} x_\lambda \\ \mu_\lambda \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ \mu_1 \end{bmatrix} + (1 - \lambda) \begin{bmatrix} x_2 \\ \mu_2 \end{bmatrix} \in \text{epi } f$$

для любого $0 \leq \lambda \leq 1$.

Следовательно, из определения надграфика, подставив значение μ_λ , получаем, что $f(x_\lambda) \leq \mu_\lambda = \lambda\mu_1 + (1 - \lambda)\mu_2$.

$$f(x_\lambda) = f(\lambda x_1 + (1 - \lambda)x_2) \leq \mu_\lambda = \lambda\mu_1 + (1 - \lambda)\mu_2$$

Но это верно для всех $\mu_1 \geq f(x_1)$ и $\mu_2 \geq f(x_2)$, в том числе и при $\mu_1 = f(x_1)$ и $\mu_2 = f(x_2)$. Тогда мы получаем неравенство:

$$f(x_\lambda) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$$

Так как $x_1 \in X$ и $x_2 \in X$ выбирались произвольно, $f(x)$ - выпуклая функция на X .

5. Дифференциальный критерий сильной выпуклости первого порядка.

i Пусть $f(x)$ — дифференцируемая функция на выпуклом множестве $X \subseteq \mathbb{R}^n$. Тогда $f(x)$ сильно выпукла на X с константой $\mu > 0$ тогда и только тогда, когда

$$f(x) - f(x_0) \geq \langle \nabla f(x_0), x - x_0 \rangle + \frac{\mu}{2} \|x - x_0\|^2$$

для всех $x, x_0 \in X$.

Необходимость

Пусть $0 < \lambda \leq 1$. Согласно определению сильно выпуклой функции,

$$f(\lambda x + (1 - \lambda)x_0) \leq \lambda f(x) + (1 - \lambda)f(x_0) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - x_0\|^2$$

или эквивалентно,

$$\begin{aligned} f(x) - f(x_0) - \frac{\mu}{2} (1 - \lambda) \|x - x_0\|^2 &\geq \frac{1}{\lambda} [f(\lambda x + (1 - \lambda)x_0) - f(x_0)] = \\ &= \frac{1}{\lambda} [f(x_0 + \lambda(x - x_0)) - f(x_0)] = \frac{1}{\lambda} [\lambda \langle \nabla f(x_0), x - x_0 \rangle + o(\lambda)] = \\ &= \langle \nabla f(x_0), x - x_0 \rangle + \frac{o(\lambda)}{\lambda}. \end{aligned}$$

Таким образом, переходя к пределу при $\lambda \rightarrow 0$, мы приходим к первоначальному утверждению.

Достаточность

Предположим, что неравенство в теореме выполнено для всех $x, x_0 \in X$. Возьмем $x_0 = \lambda x_1 + (1 - \lambda)x_2$, где $x_1, x_2 \in X$, $0 \leq \lambda \leq 1$. Согласно неравенству из условия теоремы, выполняются следующие неравенства:

$$f(x_1) - f(x_0) \geq \langle \nabla f(x_0), x_1 - x_0 \rangle + \frac{\mu}{2} \|x_1 - x_0\|^2,$$

$$f(x_2) - f(x_0) \geq \langle \nabla f(x_0), x_2 - x_0 \rangle + \frac{\mu}{2} \|x_2 - x_0\|^2.$$

Умножая первое неравенство на λ и второе на $1 - \lambda$ и складывая их, учитывая, что

$$x_1 - x_0 = (1 - \lambda)(x_1 - x_2), \quad x_2 - x_0 = \lambda(x_2 - x_1),$$

и что $\lambda(1 - \lambda)^2 + \lambda^2(1 - \lambda) = \lambda(1 - \lambda)$, получаем:

$$\begin{aligned} \lambda f(x_1) + (1 - \lambda)f(x_2) - f(x_0) - \frac{\mu}{2}\lambda(1 - \lambda)\|x_1 - x_2\|^2 &\geq \\ &\geq \langle \nabla f(x_0), \lambda x_1 + (1 - \lambda)x_2 - x_0 \rangle = 0. \end{aligned}$$

Таким образом, неравенство из определения сильно выпуклой функции выполнено. Важно отметить, что при $\mu = 0$ получаем случай выпуклости и соответствующий дифференциальный критерий.

6. Дифференциальный критерий сильной выпуклости второго порядка.

i Пусть $X \subseteq \mathbb{R}^n$ — выпуклое множество с непустой внутренностью. Пусть также $f(x)$ — дважды непрерывно дифференцируемая функция на X . Тогда $f(x)$ сильно выпукла на X с константой $\mu > 0$ тогда и только тогда, когда

$$\langle y, \nabla^2 f(x)y \rangle \geq \mu \|y\|^2$$

для всех $x \in X$ и $y \in \mathbb{R}^n$.

Другая форма записи:

$$\nabla^2 f(x) \succcurlyeq \mu I$$

Целевое неравенство тривиально, когда $y = 0_n$, поэтому предположим, что $y \neq 0_n$.

Необходимость

Пусть x является внутренней точкой X . Тогда $x + \alpha y \in X$ для всех $y \in \mathbb{R}^n$ и достаточно малых α . Поскольку $f(x)$ дважды дифференцируема,

$$f(x + \alpha y) = f(x) + \alpha \langle \nabla f(x), y \rangle + \frac{\alpha^2}{2} \langle y, \nabla^2 f(x)y \rangle + o(\alpha^2).$$

Основываясь на критерии первого порядка сильной выпуклости, имеем

$$\frac{\alpha^2}{2} \langle y, \nabla^2 f(x)y \rangle + o(\alpha^2) = f(x + \alpha y) - f(x) - \alpha \langle \nabla f(x), y \rangle \geq \frac{\mu}{2} \alpha^2 \|y\|^2.$$

Это неравенство сводится к целевому неравенству после деления обеих частей на α^2 и перехода к пределу при $\alpha \rightarrow 0$.

Если $x \in X$, но $x \notin \text{int}X$, рассмотрим последовательность $\{x_k\}$ такую, что $x_k \in \text{int}X$ и $x_k \rightarrow x$ при $k \rightarrow \infty$. Тогда мы приходим к целевому неравенству после перехода к пределу.

Достаточность

Формула Тейлора с остаточным членом Лагранжа второго порядка $\forall x, y : x, x + y \in X$ найдется α такая, что:

$$f(x+y) = f(x) + \langle \nabla f(x), y \rangle + \frac{1}{2} \langle y, \nabla^2 f(x + \alpha y) y \rangle$$

где $0 < \alpha < 1$.

Используя формулу Тейлора с остаточным членом Лагранжа и неравенство из условия, получаем для $x + y \in X$:

$$f(x+y) - f(x) - \langle \nabla f(x), y \rangle = \frac{1}{2} \langle y, \nabla^2 f(x + \alpha y) y \rangle \geq \frac{\mu}{2} \|y\|^2,$$

где $0 \leq \alpha \leq 1$. Следовательно,

$$f(x+y) - f(x) \geq \langle \nabla f(x), y \rangle + \frac{\mu}{2} \|y\|^2.$$

Таким образом, по критерию первого порядка сильной выпуклости, функция $f(x)$ является сильно выпуклой с константой μ . Важно отметить, что $\mu = 0$ соответствует случаю выпуклости и соответствующему дифференциальному критерию.

7. Необходимые условия безусловного экстремума.

i Если в x^* достигается локальный минимум и f непрерывно дифференцируема в открытой окрестности x^* , то

$$\nabla f(x^*) = 0$$

Предположим обратное. Пусть $\nabla f(x^*) \neq 0$. Рассмотрим вектор $p = -\nabla f(x^*)$ и заметим, что

$$p^T \nabla f(x^*) = -\|\nabla f(x^*)\|^2 < 0$$

Так как ∇f непрерывна в окрестности x^* , то существует скаляр $T > 0$ такой, что

$$p^T \nabla f(x^* + tp) < 0, \text{ для любого } t \in [0, T]$$

Для любого $\bar{t} \in (0, T]$, мы можем воспользоваться теоремой Тейлора:

$$f(x^* + \bar{t}p) = f(x^*) + \bar{t}p^T \nabla f(x^* + tp), \text{ для некоторого } t \in (0, \bar{t})$$

Следовательно, $f(x^* + \bar{t}p) < f(x^*)$ для любого $\bar{t} \in (0, T]$. Мы нашли направление, идя вдоль которого из x^* функция f убывает. Тогда x^* – не точка локального минимума. Получили противоречие.

8. Достаточные условия безусловного экстремума.

i Пусть $\nabla^2 f$ непрерывна в открытой окрестности x^* и

$$\nabla f(x^*) = 0 \quad \nabla^2 f(x^*) \succ 0.$$

Тогда x^* – точка локального минимума f .

Так как гессиан непрерывен и положительно определен в x^* , то мы можем выбрать радиус $r > 0$ такой, что $\nabla^2 f(x)$ остается положительно определенной для всех x в открытом шаре $B = \{z \mid$

$\|z - x^*\| < r\}$. Взяв любой ненулевой вектор p , для которого выполняется $\|p\| < r$, мы получаем $x^* + p \in B$, а также по формуле Тейлора:

$$\begin{aligned} f(x^* + p) &= f(x^*) + p^T \nabla f(x^*) + \frac{1}{2} p^T \nabla^2 f(z) p \\ &= f(x^*) + \frac{1}{2} p^T \nabla^2 f(z) p \end{aligned}$$

где $z = x^* + tp$ для некоторого $t \in (0, 1)$. Так как $z \in B$, мы получаем $p^T \nabla^2 f(z) p > 0$, и следовательно $f(x^* + p) > f(x^*)$. Таким образом x^* – точка локального минимума.

9. Симплекс метод для задачи линейного программирования с ограничениями в форме неравенств. Двухфазный симплекс метод.

i Решаемая задача:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{s.t.} \quad & Ax \leq b \end{aligned}$$

Идея метода:

1. Убедится, что точка, в которой мы находимся, является угловой
2. Проверить оптимальность точки
3. Если необходимо, сменить угол (то есть сменить базис)
4. Повторять до сходимости

Идея двухфазного симплекс метода:

1. Сформулировать вспомогательную задачу линейного программирования, решение которой даст начальную базисную допустимую точку для исходной задачи.
2. Угадать начальную базисную допустимую точку для вспомогательной задачи и решить её (симплекс методом).
3. Использовать решение вспомогательной задачи как начальную базисную допустимую точку для исходной задачи.

Задача линейного программирования с ограничениями в форме неравенств:

Пусть $c \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, $A \in \mathbb{R}^{m \times n}$, тогда задача формулируется так:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{s.t.} \quad & Ax \leq b \end{aligned}$$

Шаги выполнения симплекс метода:

1. Поиск начальной базисной допустимой точки:

- Выберем начальную базисную точку (она является решением системы $A_{\mathcal{B}} x_0 = b_{\mathcal{B}}$, где $\mathcal{B}$ - базис размера n , а матрица A обычно имеет больше n ограничений) допустимую ($Ax_0 \leq b$) точку x_0 (искать её будем через двухфазный симплекс-метод). $A_{\mathcal{B}} \in \mathbb{R}^{n \times n}$ - подматрица матрицы A с базисными строками, $b_{\mathcal{B}} \in \mathbb{R}^n$ - подвектор вектора b с базисными строками.

2. Проверка оптимальности:

- Разложение вектора c в данном базисе $\mathcal{B}$ с коэффициентами $\lambda_{\mathcal{B}}$:

$$\lambda_{\mathcal{B}}^{\top} A_{\mathcal{B}} = c^{\top} \quad \text{или} \quad \lambda_{\mathcal{B}}^{\top} = c^{\top} A_{\mathcal{B}}^{-1}$$

- Если все компоненты $\lambda_{\mathcal{B}}$ неположительны, текущий базис является оптимальным. Иначе далее меняем вершину симплекса.

3. Определение переменной для удаления из базиса:

- Если в разложении $\lambda_{\mathcal{B}}$ есть положительные координаты, продолжаем оптимизацию. Пусть $\lambda_{\mathcal{B}}^k > 0$. Необходимо исключить k из базиса. Рассчитаем направляющий вектор d , идя вдоль которого изменим вершину следующим образом: во-первых, для всех векторов ограничений из базиса, которые мы оставляем, подбираемое направление должно быть им ортогонально (т.е. движение вдоль него не будет нарушать остальные ограничения), и, во-вторых, вдоль него значение, связанное с нашим ограничением, должно убывать:

$$\begin{cases} A_{\mathcal{B} \setminus \{k\}} d = 0 \\ a_k^{\top} d < 0 \end{cases}$$

4. Вычисление шага вдоль выбранного направления d :

- Для всех $j \notin \mathcal{B}$ считаем шаг:

$$\mu_j = \frac{b_j - a_j^{\top} x_{\mathcal{B}}}{a_j^{\top} d}$$

- Новая вершина, которую добавим в базис:

$$t = \arg \min_j \{\mu_j \mid \mu_j > 0\}$$

5. Обновление базиса:

- Обновляем базис и текущее решение:

$$\begin{aligned} \mathcal{B}' &= \mathcal{B} \setminus \{k\} \cup \{t\}, \\ x_{\mathcal{B}'} &= x_{\mathcal{B}} + \mu_t d = A_{\mathcal{B}'}^{-1} b_{\mathcal{B}'} \end{aligned}$$

- Изменение базиса приводит к уменьшению значения целевой функции:

$$c^{\top} x_{\mathcal{B}'} = c^{\top} (x_{\mathcal{B}} + \mu_t d) = c^{\top} x_{\mathcal{B}} + \mu_t c^{\top} d$$

6. Повторение:

- Далее повторяем шаги 2-5 до достижения оптимального решения или установления, что задача не имеет допустимого решения.

Нахождение начальной базисной допустимой точки

Целью является решение следующей задачи:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^{\top} x \\ \text{s.t.} \quad & Ax \leq b \end{aligned} \tag{1}$$

Предложенный алгоритм требует начальной базисной допустимой точки и соответствующего базиса.

Начнем с переформулирования задачи:

$$\begin{aligned} \min_{y \in \mathbb{R}^n, z \in \mathbb{R}^n} \quad & c^\top (y - z) \\ \text{s.t.} \quad & Ay - Az \leq b \\ & y \geq 0, z \geq 0 \end{aligned} \quad (2)$$

Имея решение задачи 2, решение задачи 1 может быть однозначно получено и наоборот:

$$x = y - z \quad \Leftrightarrow \quad y_i = \max(x_i, 0), \quad z_i = \max(-x_i, 0)$$

Теперь мы попытаемся сформулировать новую задачу ЛП, решение которой будет базисной допустимой точкой для задачи 2. Это означает, что мы сначала запустим симплекс-метод для задачи 2, а затем запустим задачу 1 с известной начальной точкой. Обратите внимание, что базисная допустимая точка для задачи 2 должна быть легко вычислима.

$$\begin{aligned} \min_{y \in \mathbb{R}^n, z \in \mathbb{R}^n} \quad & c^\top (y - z) \\ \text{s.t.} \quad & Ay - Az \leq b \\ & y \geq 0, z \geq 0 \end{aligned} \quad (\text{Phase-2 (Main LP)})$$

$$\begin{aligned} \min_{\xi \in \mathbb{R}^m, y \in \mathbb{R}^n, z \in \mathbb{R}^n} \quad & \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & Ay - Az \leq b + \xi \\ & y \geq 0, z \geq 0, \xi \geq 0 \end{aligned} \quad (\text{Phase-1})$$

- Если задача 2 имеет допустимое решение, то оптимум задачи 2 равен нулю (т.е. все переменные ξ_i равны нулю).

Доказательство: тривиальная проверка.

- Если оптимум задачи 2 равен нулю (т.е. все переменные ξ_i равны нулю), то мы получаем допустимый базис для задачи 2.

Доказательство: тривиальная проверка.

- Теперь мы знаем, что если мы можем решить задачу 2, то мы либо найдем начальную точку для симплекс-метода в исходной задаче (если все переменные ξ_i равны нулю), либо проверим, что исходная задача не имеет допустимого решения (если все переменные ξ_i не равны нулю).
- Но как решить задачу 2? Она имеет базисную допустимую точку (задача имеет $2n + m$ переменных и точка ниже гарантирует, что $2n + m$ неравенств выполняются как равенства (активны)).

$$z = 0 \quad y = 0 \quad \xi_i = \max(0, -b_i)$$

10. Теорема о проверке оптимальности решения в линейном программировании. Теорема о сильной двойственности в задаче линейного программирования.

i В задаче линейного программирования с ограничениями в форме неравенств, если все элементы $\lambda_{\mathcal{B}}$ неположительны и базис $\mathcal{B}$ - допустимый, тогда базис $\mathcal{B}$ оптимален.

Прямая задача ЛП:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & x_i \geq 0, \quad i = 1, \dots, n \end{aligned} \quad (3)$$

Двойственная задача ЛП:

$$\begin{aligned} \max_{\nu \in \mathbb{R}^m} \quad & -b^\top \nu \\ \text{s.t.} \quad & -A^\top \nu \preceq c \end{aligned} \quad (4)$$

- (i) Если одна из задач (3) или (4) имеет конечное решение, то и другая имеет конечное решение, и значения целевых функций равны.
- (ii) Если одна из задач (3) или (4) неограничена, то другая задача не имеет допустимого решения.




Рисунок 24: Иллюстрация задачи (1)

Решаемая задача:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^\top x \\ \text{s.t.} \quad & Ax \leq b \end{aligned}$$

Пусть $\mathcal{B}$ - базис размера n , а матрица A обычно имеет больше n ограничений. Тогда выбранному набору индексу (базису) соответствует подматрица $A_{\mathcal{B}}$ и подвектор $b_{\mathcal{B}}$, а так же решение $x_{\mathcal{B}} =$

$$A_{\mathcal{B}}^{-1}b_{\mathcal{B}}.$$

Разложим вектор c в выбранном базисе $\mathcal{B}$:

$$\lambda_{\mathcal{B}}^T A_{\mathcal{B}} = c^T \leftrightarrow \lambda_{\mathcal{B}}^T = c^T A_{\mathcal{B}}^{-1}$$

Здесь $\lambda_{\mathcal{B}}$ это коэффициенты при разложении c по базису $\mathcal{B}$: $\lambda_{\mathcal{B}}^T A_{\mathcal{B}} = c^T \Rightarrow \lambda_{\mathcal{B}}^T = c^T A_{\mathcal{B}}^{-1}$.

Доказательство:

Предположим противное (что этот базис не оптимален), пусть $\exists x^* : Ax^* \leq b$ и при этом $c^T x^* < c^T x_{\mathcal{B}}$. Так как для всей матрицы A и вектора b неравенство верно, то и для подматрицы оно верно:

$$A_{\mathcal{B}} x^* \leq b_{\mathcal{B}}$$

Так как все элементы $\lambda_{\mathcal{B}}$ неположительны, то домножим строки на соответствующие элементы и сложим:

$$\lambda_{\mathcal{B}}^T A_{\mathcal{B}} x^* \geq \lambda_{\mathcal{B}}^T b_{\mathcal{B}}$$

$$c^T x^* \geq \lambda_{\mathcal{B}}^T b_{\mathcal{B}} = \lambda_{\mathcal{B}}^T A_{\mathcal{B}} x_{\mathcal{B}} = c^T x_{\mathcal{B}}$$

Противоречие.

Рассмотрим прямую задачу ЛП в следующей форме:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & x_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$

ККТ для оптимального решения x^*, ν^*, λ^* :

$$\begin{aligned} L(x, \nu, \lambda) &= c^T x + \nu^T (Ax - b) - \lambda^T x \\ &\quad - A^T \nu^* + \lambda^* = c \\ Ax^* &= b \\ x^* &\succeq 0 \\ \lambda^* &\succeq 0 \\ \lambda_i^* x_i^* &= 0 \end{aligned}$$

Двойственная задача ЛП:

$$\begin{aligned} \max_{\nu \in \mathbb{R}^m} \quad & -b^T \nu \\ \text{s.t.} \quad & -A^T \nu \preceq c \end{aligned}$$

1. Предположим, что задача 3 имеет конечное оптимальное решение x^* . Из ККТ следует, что существуют оптимальные векторы λ^* и ν^* такие, что (x^*, ν^*, λ^*) удовлетворяет ККТ. Кроме того, $c^T x^* = (-A^T \nu^* + \lambda^*)^T x^* = -(\nu^*)^T A x^* = -b^T \nu^*$, как утверждается.

Симметричные рассуждения справедливы, если мы начнем с предположения, что двойственная задача задачи 4 имеет решение.

2. Предположим, что прямая задача 3 неограничена, то есть существует последовательность точек $x_k, k = 1, 2, 3, \dots$ такая, что

$$c^T x_k \downarrow -\infty, \quad Ax_k = b, \quad x_k \geq 0.$$

Предположим также, что двойственная задача 4 допустима, то есть существует вектор $\bar{v}$ такой, что $-A^T \bar{v} \leq c$. Из последнего неравенства вместе с $x_k \geq 0$ следует, что $-\bar{v}^T Ax_k \leq c^T x_k$, и, следовательно,

$$-\bar{v}^T b = -\bar{v}^T Ax_k \leq c^T x_k \downarrow -\infty,$$

противоречие. Следовательно, двойственная задача не имеет допустимого решения. Аналогичный аргумент может быть использован для доказательства того, что неограниченность двойственной задачи влечет неограниченность прямой задачи.

11. Теорема сходимости градиентного спуска для гладких выпуклых функций.

i Рассматриваем задачу

$$f(x) \rightarrow \min_{x \in \mathbb{R}^d}$$

и предполагаем, что f - выпуклая, L -гладкая, $L > 0$.

Пусть $(x_k)_{k \in \mathbb{N}}$ это последовательность, созданная градиентным спуском с постоянным шагом $\alpha, 0 < \alpha \leq \frac{1}{L}$. Тогда градиентный спуск сходится сублинейно, то есть:

$$f(x_k) - f^* \leq \frac{\|x_0 - x^*\|^2}{2\alpha k}.$$

1. Формулировка метода:

$$x_{k+1} = x_k - \alpha \nabla f(x_k) \Rightarrow x_{k+1} - x_k = -\alpha \nabla f(x_k)$$

2. L -гладкость: $\forall x, y : f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$

$$y := x_{k+1}, x := x_k \Rightarrow f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), -\alpha \nabla f(x_k) \rangle + \frac{L}{2} \alpha^2 \|\nabla f(x_k)\|^2$$

$$f(x_{k+1}) \leq f(x_k) - \alpha \|\nabla f(x_k)\|^2 + \frac{L}{2} \alpha^2 \|\nabla f(x_k)\|^2 \quad (1)$$

3. Решим задачу оптимизации для поиска оптимального постоянного шага $(\frac{L}{2} \alpha^2 - \alpha) \rightarrow \min_{\alpha}$.

Получаем оптимальный шаг: $\alpha = \frac{1}{L}$ и $f(x_k) - f(x_{k+1}) \geq \frac{1}{2L} \|\nabla f(x_k)\|^2$

4. Выпуклость: $f(y) \geq f(x) + \nabla f(x)^T (y - x)$

$$\begin{aligned} y := x^*, x := x_k &\Rightarrow f(x^*) \geq f(x_k) + \nabla f(x_k)^T (x^* - x_k) \Rightarrow \\ &\Rightarrow f(x_k) \leq f(x^*) + \nabla f(x_k)^T (x_k - x^*) \Rightarrow f(x_k) - f(x^*) \leq \nabla f(x_k)^T (x_k - x^*) \end{aligned}$$

5. Подставим выпуклость в (1):

$$\begin{aligned} f(x_{k+1}) &\leq f(x_k) - \frac{\alpha}{2} \|\nabla f(x_k)\|^2 \leq f^* + \langle \nabla f(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|\nabla f(x_k)\|^2 \\ &= f^* + \langle \nabla f(x_k), x_k - x^* - \frac{\alpha}{2} \nabla f(x_k) \rangle \\ &= f^* + \frac{1}{2\alpha} \left\langle \alpha \nabla f(x_k), 2 \left(x_k - x^* - \frac{\alpha}{2} \nabla f(x_k) \right) \right\rangle \end{aligned}$$

6. Пусть $a = x_k - x^*$ и $b = x_k - x^* - \alpha \nabla f(x_k)$. Тогда $a + b = \alpha \nabla f(x_k)$ и $a - b = 2(x_k - x^* - \frac{\alpha}{2} \nabla f(x_k))$.

$$\begin{aligned} f(x_{k+1}) &\leq f^* + \frac{1}{2\alpha} [\|x_k - x^*\|_2^2 - \|x_k - x^* - \alpha \nabla f(x_k)\|_2^2] \\ &\leq f^* + \frac{1}{2\alpha} [\|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2] \\ 2\alpha (f(x_{k+1}) - f^*) &\leq \|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2 \end{aligned}$$

7. Предположим, что последняя строка определена для некоторого индекса i и мы суммируем по $i \in [0, k-1]$. Большинство слагаемых будут равны нулю из-за телескопической природы суммы:

$$2\alpha \sum_{i=0}^{k-1} (f(x_{i+1}) - f^*) \leq \|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2 \leq \|x_0 - x^*\|_2^2 \quad (5)$$

8. Из-за монотонного убывания на каждой итерации $f(x_{i+1}) < f(x_i)$:

$$kf(x_k) \leq \sum_{i=0}^{k-1} f(x_{i+1})$$

9. Подставим в (5):

$$\begin{aligned} 2\alpha k f(x_k) - 2\alpha k f^* &\leq 2\alpha \sum_{i=0}^{k-1} (f(x_{i+1}) - f^*) \leq \|x_0 - x^*\|_2^2 \\ f(x_k) - f^* &\leq \frac{\|x_0 - x^*\|_2^2}{2\alpha k} \leq \frac{L\|x_0 - x^*\|_2^2}{2k} \end{aligned}$$

То есть сходимость сублинейная.

12. Теорема сходимости градиентного спуска для гладких PL функций.

i Рассмотрим задачу

$$f(x) \rightarrow \min_{x \in \mathbb{R}^d}$$

и предположим, что f удовлетворяет условию Поляка-Лоясиевича с константой μ и L -гладкости, для некоторых $L \geq \mu > 0$. Пусть $(x_k)_{k \in \mathbb{N}}$ - последовательность, созданная градиентным спуском с постоянным шагом α , $0 < \alpha \leq \frac{1}{L}$. Тогда имеется линейная сходимость:

$$f(x_k) - f^* \leq (1 - \alpha\mu)^k (f(x_0) - f^*).$$

1. Используя L -гладкость, вместе с правилом обновления алгоритма, можно записать:

$$\begin{aligned} f(x_{k+1}) &\leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2 \\ &= f(x_k) - \alpha \|\nabla f(x_k)\|^2 + \frac{L\alpha^2}{2} \|\nabla f(x_k)\|^2 \\ &= f(x_k) - \frac{\alpha}{2} (2 - L\alpha) \|\nabla f(x_k)\|^2 \\ &\leq f(x_k) - \frac{\alpha}{2} \|\nabla f(x_k)\|^2, \end{aligned}$$

В последнем неравенстве использовали предположение о шаге $0 < \alpha L \leq 1$.

2. Используя свойство Поляка-Лоясиевича, можно записать:

$$f(x_{k+1}) \leq f(x_k) - \alpha\mu(f(x_k) - f^*).$$

3. Вычитая f^* с обеих сторон и используя рекурсию, получаем:

$$f(x_k) - f^* \leq (1 - \alpha\mu)^k (f(x_0) - f^*).$$

13. Теорема сходимости градиентного спуска для сильно выпуклых квадратичных функций. Оптимальные гиперпараметры.

i

$$f(x) \rightarrow \min_{x \in \mathbb{R}^d}$$

$$f(x) = \frac{1}{2}x^T A x - b^T x + c, \quad A \in \mathbb{S}_{++}$$

Тогда градиентный спуск с шагом $\alpha = \frac{2}{\mu+L}$ сходится линейно с показателем $\frac{L-\mu}{L+\mu}$

$$f(x_k) - f^* \leq \left(\frac{L-\mu}{L+\mu} \right)^k (f(x_0) - f^*).$$

$$\nabla f(x) = Ax - b \stackrel{\nabla f(x^*)=0}{\Rightarrow} Ax^* = b$$

Тогда шаг градиентного спуска имеет вид

$$x_{k+1} = x_k - \alpha(Ax - b)$$

Найдем α^* . Воспользуемся $A = Q\Lambda Q^T$, где $\Lambda = \text{diag}\{\lambda_1, \dots, \lambda_n\}$, $Q = \|q_1, \dots, q_n\|$, λ_i, q_i - собственное значение и собственный вектор соответственно.

$$x_{k+1} = (I - \alpha A)x_k + \alpha Ax^* - x^*$$

$$x_{k+1} - x^* = (I - \alpha A)(x_k - x^*)$$

$$x_{k+1} - x^* = (I - \alpha Q\Lambda Q^T)(x_k - x^*) \cdot Q^T$$

$$Q^T(x_{k+1} - x^*) = (Q^T - \alpha\Lambda Q^T)(x_k - x^*) = (I - \alpha\Lambda)Q^T(x_k - x^*)$$

$$\text{Замена: } \tilde{x} = Q^T(x - x^*) \Rightarrow \tilde{x}_{k+1} = (I - \alpha\Lambda)\tilde{x}_k \Leftrightarrow \tilde{x}_i^{(k+1)} = (1 - \alpha\lambda_i)\tilde{x}_i^{(k)} \quad i = \overline{1, d}$$

$$\lambda_{\min} = \mu, \quad \lambda_{\max} = L$$

Сходимость есть $\Leftrightarrow \max_i |1 - \alpha\lambda_i| < 1$

$$\left\{ \begin{array}{l} |1 - \lambda\mu| < 1 \Rightarrow 1 - \lambda\mu < 1 \Rightarrow \alpha > 0 \\ \alpha\mu - 1 < 1 \Rightarrow \alpha < \frac{2}{\mu} \\ |1 - \alpha L| < 1 \Rightarrow 1 - \alpha L < 1 \Rightarrow \alpha > 0 \\ \alpha L - 1 < 1 \Rightarrow \alpha < \frac{2}{L} \end{array} \right\} \Rightarrow \alpha < \frac{2}{L}$$

Радиус сходимости $\rho = \max(|1 - \alpha\mu|, |1 - \alpha L|)$ и $\rho \rightarrow \min \Leftrightarrow \alpha^* L - 1 = 1 - \alpha^* \mu \Rightarrow \alpha^* = \frac{2}{\mu+L}$ и $\rho^* = \frac{L-\mu}{L+\mu}$

Итого получаем, что для градиентного спуска выполняется $f(x_k) - f^* \leq \left(1 - \frac{\mu}{\mu+L}\right)^k (f(x_0) - f^*)$.

14. Вывод ускоренного метода для квадратичной функции с помощью полиномов Чебышёва.

i Решаем квадратичную задачу:

$$f(x) = \frac{1}{2}x^T A x - b^T x \quad x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Можно показать, что метод, полученный с помощью полиномов Чебышёва, имеет вид:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$

обладает ускоренной линейной сходимостью.

1. Пусть x^* - единственное решение линейной системы $Ax = b$ и пусть $e_k = x_k - x^*$, где $x_{k+1} = x_k - \alpha_k (Ax_k - b)$ определяется рекурсивно, начиная с некоторого x_0 , и α_k - шаг, который мы определим позже.

$$e_{k+1} = (I - \alpha_k A) e_k.$$

1. Вышеуказанный расчет дает нам $e_k = p_k(A) e_0$, где p_k - полином

$$p_k(a) = \prod_{i=1}^k (1 - \alpha_i a).$$

Мы можем ограничить сверху норму ошибки как

$$\|e_k\| \leq \|p_k(A)\| \cdot \|e_0\|.$$

Поскольку A - симметричная матрица с собственными значениями в $[\mu, L]$,

$$\|p_k(A)\| \leq \max_{\mu \leq a \leq L} |p_k(a)|.$$

Это приводит к интересной проблеме: среди всех полиномов, удовлетворяющих $p_k(0) = 1$, мы ищем полином, величина которого наименьшая в интервале $[\mu, L]$.


2. Наивный подход состоит в выборе равномерного шага $\alpha_k = \frac{2}{\mu+L}$ в выражении. Этот выбор делает $|p_k(\mu)| = |p_k(L)|$.

$$\|e_k\| \leq \left(\frac{L - \mu}{L + \mu} \right)^k \|e_0\|$$

Это точно такой же результат, который мы доказали для сходимости градиентного спуска в случае квадратичной функции.

Давайте взглянем на этот полином поближе. На правом рисунке мы выбрали $\alpha = 1$ и $\beta = 10$ так, что $\kappa = 10$. Соответствующий интервал, таким образом, равен $[1, 10]$.

Можем ли мы сделать лучше? Ответ - да.




3. Полиномы Чебышёва оказываются оптимальным ответом на вопрос, который мы задавали. Соответствующим образом масштабированные, они минимизируют абсолютное значение в желаемом интервале $[\mu, L]$ при условии, что значение равно 1 в начале.

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

4. Давайте построим стандартные полиномы Чебышёва (без масштабирования):



5. Исходные полиномы Чебышёва определяются на интервале $[-1, 1]$. Чтобы использовать их для наших целей, нам нужно их масштабировать на интервал $[\mu, L]$.
6. Мы будем использовать следующую аффинную трансформацию:

$$x = \frac{L + \mu - 2a}{L - \mu}, \quad a \in [\mu, L], \quad x \in [-1, 1].$$






7. Обратите внимание, что $x = 1$ соответствует $a = \mu$, $x = -1$ соответствует $a = L$ и $x = 0$ соответствует $a = \frac{\mu+L}{2}$. Эта трансформация гарантирует, что поведение полинома Чебышёва на интервале $[-1, 1]$ отражается в интервал $[\mu, L]$
8. В нашем анализе ошибок мы требуем, чтобы полином был равен 1 в 0 (т.е., $p_k(0) = 1$). После применения трансформации значение T_k в точке, соответствующей $a = 0$, может не быть 1. Таким образом, мы нормируем полином T_k , деля его на значение $T_k\left(\frac{L+\mu}{L-\mu}\right)$:


$$\frac{L + \mu}{L - \mu}, \quad \text{гарантируя, что} \quad P_k(0) = T_k\left(\frac{L + \mu - 0}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = 1.$$

9. Давайте построим масштабированные полиномы Чебышёва

$$P_k(a) = T_k\left(\frac{L + \mu - 2a}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1}$$

и наблюдаем, что они значительно лучше ведут себя в интервале $[\mu, L]$ по сравнению с наивными полиномами.





10. Мы видим, что максимальное значение полинома Чебышёва на интервале $[\mu, L]$ достигается в точке $a = \mu$. Следовательно, мы можем использовать следующую верхнюю границу:

$$\|P_k(A)\|_2 \leq P_k(\mu) = T_k\left(\frac{L + \mu - 2\mu}{L - \mu}\right) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k(1) \cdot T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1} = T_k\left(\frac{L + \mu}{L - \mu}\right)^{-1}$$

11. Используя определение числа обусловленности $\kappa = \frac{L}{\mu}$, мы получаем:

$$\|P_k(A)\|_2 \leq T_k\left(\frac{\kappa + 1}{\kappa - 1}\right)^{-1} = T_k\left(1 + \frac{2}{\kappa - 1}\right)^{-1} = T_k(1 + \epsilon)^{-1}, \quad \epsilon = \frac{2}{\kappa - 1}.$$

12. Следовательно, нам нужно только понять значение T_k в $1 + \epsilon$. Это то, откуда берется ускорение. Мы будем ограничивать это значение сверху величиной $\mathcal{O}\left(\frac{1}{\sqrt{\epsilon}}\right)$.

13. Чтобы ограничить $|P_k|$ сверху, нам нужно оценить $|T_k(1 + \epsilon)|$ снизу.

14. Для любого $x \geq 1$, полином Чебышёва первого рода может быть записан как

$$\begin{aligned} T_k(x) &= \cosh(k \operatorname{arccosh}(x)) \\ T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)). \end{aligned}$$

15. Для любого $x \geq 1$, полином Чебышёва первого рода может быть записан как

$$\begin{aligned} T_k(x) &= \cosh(k \operatorname{arccosh}(x)) \\ T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)). \end{aligned}$$

16. Помним, что:

$$\cosh(x) = \frac{e^x + e^{-x}}{2} \quad \operatorname{arccosh}(x) = \ln(x + \sqrt{x^2 - 1}).$$

17. Пусть $\phi = \operatorname{arccosh}(1 + \epsilon)$,

$$e^\phi = 1 + \epsilon + \sqrt{2\epsilon + \epsilon^2} \geq 1 + \sqrt{\epsilon}.$$

18. Следовательно,

$$\begin{aligned} T_k(1 + \epsilon) &= \cosh(k \operatorname{arccosh}(1 + \epsilon)) \\ &= \cosh(k\phi) \\ &= \frac{e^{k\phi} + e^{-k\phi}}{2} \geq \frac{e^{k\phi}}{2} \\ &= \frac{(1 + \sqrt{\epsilon})^k}{2}. \end{aligned}$$

19. Наконец, мы получаем:

$$\begin{aligned}\|e_k\| &\leq \|P_k(A)\| \|e_0\| \leq \frac{2}{(1 + \sqrt{\epsilon})^k} \|e_0\| \\ &\leq 2 \left(1 + \sqrt{\frac{2}{\kappa - 1}}\right)^{-k} \|e_0\| \\ &\leq 2 \exp\left(-\sqrt{\frac{2}{\kappa - 1}} k\right) \|e_0\|\end{aligned}$$

20. Из-за рекурсивного определения полиномов Чебышёва, мы непосредственно получаем итерационную схему ускорения. Переформулируя рекуррентное соотношение в терминах наших масштабированных полиномов Чебышёва, мы получаем:

$$T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x)$$

Поскольку $x = \frac{L+\mu-2a}{L-\mu}$, и:

$$\begin{aligned}P_k(a) &= T_k\left(\frac{L+\mu-2a}{L-\mu}\right) T_k\left(\frac{L+\mu}{L-\mu}\right)^{-1} \\ T_k\left(\frac{L+\mu-2a}{L-\mu}\right) &= P_k(a) T_k\left(\frac{L+\mu}{L-\mu}\right) \\ T_{k-1}\left(\frac{L+\mu-2a}{L-\mu}\right) &= P_{k-1}(a) T_{k-1}\left(\frac{L+\mu}{L-\mu}\right) \\ T_{k+1}\left(\frac{L+\mu-2a}{L-\mu}\right) &= P_{k+1}(a) T_{k+1}\left(\frac{L+\mu}{L-\mu}\right) \\ P_{k+1}(a) t_{k+1} &= 2 \frac{L+\mu-2a}{L-\mu} P_k(a) t_k - P_{k-1}(a) t_{k-1}, \text{ where } t_k = T_k\left(\frac{L+\mu}{L-\mu}\right) \\ P_{k+1}(a) &= 2 \frac{L+\mu-2a}{L-\mu} P_k(a) \frac{t_k}{t_{k+1}} - P_{k-1}(a) \frac{t_{k-1}}{t_{k+1}}\end{aligned}$$

21. Поскольку мы имеем $P_{k+1}(0) = P_k(0) = P_{k-1}(0) = 1$, мы можем записать метод в следующей форме:

$$P_{k+1}(a) = (1 - \alpha_k a) P_k(a) + \beta_k (P_k(a) - P_{k-1}(a)).$$

22. Перегруппируя члены, мы получаем:



$$\begin{aligned}P_{k+1}(a) &= (1 + \beta_k) P_k(a) - \alpha_k a P_k(a) - \beta_k P_{k-1}(a), \\ P_{k+1}(a) &= 2 \frac{L+\mu}{L-\mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{4a}{L-\mu} \frac{t_k}{t_{k+1}} P_k(a) - \frac{t_{k-1}}{t_{k+1}} P_{k-1}(a) \\ &\begin{cases} \beta_k = \frac{t_{k-1}}{t_{k+1}}, \\ \alpha_k = \frac{4}{L-\mu} \frac{t_k}{t_{k+1}}, \\ 1 + \beta_k = 2 \frac{L+\mu}{L-\mu} \frac{t_k}{t_{k+1}} \end{cases}\end{aligned}$$

23. Мы почти закончили 😊. Помним, что $e_{k+1} = P_{k+1}(A)e_0$. Также отметим, что мы работаем с квадратичной задачей, поэтому мы можем предположить $x^* = 0$ без потери общности. В этом случае $e_0 = x_0$ и $e_{k+1} = x_{k+1}$.

$$\begin{aligned}x_{k+1} &= P_{k+1}(A)x_0 = (I - \alpha_k A)P_k(A)x_0 + \beta_k (P_k(A) - P_{k-1}(A))x_0 \\&= (I - \alpha_k A)x_k + \beta_k (x_k - x_{k-1})\end{aligned}$$

24. Для квадратичной задачи мы имеем $\nabla f(x_k) = Ax_k$, поэтому мы можем переписать обновление как:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$$



15. Доказательство сходимости метода сопряженных градиентов и вывод формул метода (В этом вопросе необходимо доказать за какое количество шагов сходится метод, как выбираются направления и почему в A -ортогонализации достаточно хранить лишь предыдущий шаг метода, а не все предыдущие).

i

$$\mathbf{r}_0 := \mathbf{b} - \mathbf{A}\mathbf{x}_0$$

Если $\mathbf{r}_0$ достаточно мала, то вернуть $\mathbf{x}_0$ как результат

$$\mathbf{d}_0 := \mathbf{r}_0$$

$$k := 0$$

повторить

$$\alpha_k := \frac{\mathbf{r}_k^\top \mathbf{r}_k}{\mathbf{d}_k^\top \mathbf{A} \mathbf{d}_k}$$

$$\mathbf{x}_{k+1} := \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

$$\mathbf{r}_{k+1} := \mathbf{r}_k - \alpha_k \mathbf{A} \mathbf{d}_k$$

Если $\mathbf{r}_{k+1}$ достаточно мала, то выйти из цикла

$$\beta_k := \frac{\mathbf{r}_{k+1}^\top \mathbf{r}_{k+1}}{\mathbf{r}_k^\top \mathbf{r}_k}$$

$$\mathbf{d}_{k+1} := \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k$$

$$k := k + 1$$

конец повторения

вернуть $\mathbf{x}_{k+1}$ как результат

Рассмотрим следующую квадратичную задачу оптимизации:

$$\min_{x \in \mathbb{R}^n} f(x) = \min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top A x - b^\top x + c, \text{ где } A \in \mathbb{S}_{++}^n. \quad (6)$$

Берём в арсенал процесс Грам-Шмидта:

$$d_k = u_k + \sum_{i=0}^{k-1} \beta_{ik} d_i \quad \beta_{ik} = -\frac{\langle d_i, u_k \rangle}{\langle d_i, d_i \rangle} \quad (7)$$

Лемма 1. Линейная независимость A -ортогональных векторов.

Если множество векторов $d_1, \dots, d_n$ - попарно A -ортогональны (каждая пара векторов A -ортогональна), то эти векторы линейно независимы. $A \in \mathbb{S}_{++}^n$.

Доказательство

Покажем, что если $\sum_{i=1}^n \alpha_i d_i = 0$, то все коэффициенты должны быть равны нулю:

$$\begin{aligned} 0 &= \sum_{i=1}^n \alpha_i d_i \\ \text{Умножаем на } d_j^\top A \cdot &= d_j^\top A \left(\sum_{i=1}^n \alpha_i d_i \right) = \sum_{i=1}^n \alpha_i d_j^\top A d_i \\ &= \alpha_j d_j^\top A d_j + 0 + \dots + 0 \end{aligned}$$

Таким образом, $\alpha_j = 0$, для всех остальных индексов нужно проделать тот же процесс

Введем следующие обозначения:

- $r_k = b - Ax_k$ - невязка
- $e_k = x_k - x^*$ - ошибка
- Поскольку $Ax^* = b$, имеем $r_k = b - Ax_k = Ax^* - Ax_k = -A(x_k - x^*)$

$$r_k = -Ae_k. \quad (8)$$

- Также заметим, что поскольку $x_{k+1} = x_0 + \sum_{i=1}^k \alpha_i d_i$, имеем

$$e_{k+1} = e_0 + \sum_{i=1}^k \alpha_i d_i. \quad (9)$$

Лемма 2. Сходимость метода сопряженных направлений.

Предположим, мы решаем n -мерную квадратичную сильно выпуклую задачу оптимизации (6). Метод сопряженных направлений

$$x_{k+1} = x_0 + \sum_{i=0}^k \alpha_i d_i$$

с $\alpha_i = \frac{\langle d_i, r_i \rangle}{\langle d_i, Ad_i \rangle}$ взятым из точного линейного поиска, сходится за не более n шагов алгоритма.

Доказательство

1. Нужно доказать, что $\delta_i = -\alpha_i$:

$$e_0 = x_0 - x^* = \sum_{i=0}^{n-1} \delta_i d_i$$

2. Умножаем обе части слева на $d_k^T A$:

$$d_k^T A e_0 = \sum_{i=0}^{n-1} \delta_i d_k^T A d_i = \delta_k d_k^T A d_k$$

$$d_k^T A \left(e_0 + \sum_{i=0}^{k-1} \alpha_i d_i \right) = d_k^T A e_k = \delta_k d_k^T A d_k \quad (A - \text{ ортогональность})$$

$$\delta_k = \frac{d_k^T A e_k}{d_k^T A d_k} = -\frac{d_k^T r_k}{d_k^T A d_k} \Leftrightarrow \delta_k = -\alpha_k$$

Лемма 3. Разложение ошибки.

$$e_i = \sum_{j=i}^{n-1} -\alpha_j d_j \quad (10)$$

Доказательство

По определению

$$e_i = e_0 + \sum_{j=0}^{i-1} \alpha_j d_j = x_0 - x^* + \sum_{j=0}^{i-1} \alpha_j d_j = -\sum_{j=0}^{n-1} \alpha_j d_j + \sum_{j=0}^{i-1} \alpha_j d_j = \sum_{j=i}^{n-1} -\alpha_j d_j$$

Лемма 4. Невязка ортогональна всем предыдущим направлениям для CD.

Рассмотрим невязку метода сопряженных направлений на k итерации r_k , тогда для любого $i < k$:

$$d_i^T r_k = 0 \quad (11)$$


Доказательство

Запишем (10) для некоторого фиксированного индекса k :

$$e_k = \sum_{j=k}^{n-1} -\alpha_j d_j$$

Умножаем обе части на $-d_i^T A$.

$$-d_i^T A e_k = \sum_{j=k}^{n-1} \alpha_j d_i^T A d_j = 0$$



Таким образом, $d_i^T r_k = 0$ и невязка r_k ортогональна всем предыдущим направлениям d_i для метода CD.

Идея метода сопряженных градиентов (CG)

- Это буквально метод сопряженных направлений, в котором мы выбираем специальный набор $d_0, \dots, d_{n-1}$, позволяющий значительно ускорить процесс Грама-Шмидта.
- Используется процесс Грама-Шмидта с A -ортогональностью вместо Евклидовой ортогональности, чтобы получить их из набора начальных векторов.
- На каждой итерации $r_0, \dots, r_{n-1}$ используются в качестве начальных векторов для процесса Грама-Шмидта.
- Основная идея заключается в том, что для произвольного метода CD процесс Грама-Шмидта вычислительно дорогой и требует квадратичного числа операций сложения векторов и скалярных произведений $\mathcal{O}(n^2)$, в то время как в случае CG мы покажем, что сложность этой процедуры может быть уменьшена до линейной $\mathcal{O}(n)$.

CG = CD + $r_0, \dots, r_{n-1}$ как начальные векторы для процесса Грама-Шмидта + A -ортогональность.

Лемма 5. Невязки ортогональны друг другу в методе CG

Все невязки в методе CG ортогональны друг другу:

$$r_i^T r_k = 0 \quad \forall i \neq k \quad (12)$$


Доказательство

Запишем процесс Грама-Шмидта (7) с $\langle \cdot, \cdot \rangle$ замененным на $\langle \cdot, \cdot \rangle_A = x^T A y$

$$d_i = u_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (13)$$

Тогда, мы используем невязки в качестве начальных векторов для процесса и $u_i = r_i$.

$$d_i = r_i + \sum_{j=0}^{i-1} \beta_{ji} d_j \quad \beta_{ji} = -\frac{\langle d_j, r_i \rangle_A}{\langle d_j, d_j \rangle_A} \quad (14)$$



Умножаем обе части (13) на r_k^T для некоторого индекса k :

$$r_k^T d_i = r_k^T u_i + \sum_{j=0}^{i-1} \beta_{ji} r_k^T d_j$$

Если $j < i < k$, то имеем лемму 4 с $d_i^T r_k = 0$ и $d_j^T r_k = 0$. Имеем:

$$r_k^T u_i = 0 \quad \text{для CD} \quad r_k^T r_i = 0 \quad \text{для CG}$$

Более того, если $k = i$:

$$r_k^T d_k = r_k^T u_k + \sum_{j=0}^{k-1} \beta_{jk} r_k^T d_j = r_k^T u_k + 0,$$

и мы имеем для любого k (из-за произвольного выбора i):

$$r_k^T d_k = r_k^T u_k. \quad (15)$$

Лемма 6. Пересчет невязки

$$r_{k+1} = r_k - \alpha_k A d_k \quad (16)$$

$$r_{k+1} = -A e_{k+1} = -A (e_k + \alpha_k d_k) = -A e_k - \alpha_k A d_k = r_k - \alpha_k A d_k$$

Наконец, все эти вышеуказанные леммы достаточны для доказательства, что $\beta_{ji} = 0$ для всех i, j , кроме соседних.

Грам-Шмидт в методе CG

Рассмотрим процесс Грам-Шмидта в методе CG:

$$\beta_{ji} = -\frac{\langle d_j, u_i \rangle_A}{\langle d_j, d_j \rangle_A} = -\frac{d_j^T A u_i}{d_j^T A d_j} = -\frac{d_j^T A r_i}{d_j^T A d_j} = -\frac{r_i^T A d_j}{d_j^T A d_j}.$$

Рассмотрим скалярное произведение $\langle r_i, r_{j+1} \rangle$ используя (16):

$$\begin{aligned} \langle r_i, r_{j+1} \rangle &= \langle r_i, r_j - \alpha_j A d_j \rangle = \langle r_i, r_j \rangle - \alpha_j \langle r_i, A d_j \rangle \\ \alpha_j \langle r_i, A d_j \rangle &= \langle r_i, r_j \rangle - \langle r_i, r_{j+1} \rangle \end{aligned}$$

- Если $i = j$: $\alpha_i \langle r_i, Ad_i \rangle = \langle r_i, r_i \rangle - \langle r_i, r_{i+1} \rangle = \langle r_i, r_i \rangle$. Этот случай не интересен по построению процесса Грам-Шмидта.
- Соседний случай $i = j + 1$: $\alpha_j \langle r_i, Ad_j \rangle = \langle r_i, r_{i-1} \rangle - \langle r_i, r_i \rangle = -\langle r_i, r_i \rangle$
- Для любого другого случая: $\alpha_j \langle r_i, Ad_j \rangle = 0$, потому что все невязки ортогональны друг другу.

Наконец, мы имеем формулу для $i = j + 1$:

$$\beta_{ji} = -\frac{r_i^T Ad_j}{d_j^T Ad_j} = \frac{1}{\alpha_j} \frac{\langle r_i, r_i \rangle}{d_j^T Ad_j} = \frac{d_j^T Ad_j \langle r_i, r_i \rangle}{d_j^T r_j d_j^T Ad_j} = \frac{\langle r_i, r_i \rangle}{\langle r_j, r_j \rangle} = \frac{\langle r_i, r_i \rangle}{\langle r_{i-1}, r_{i-1} \rangle}$$

И для направления $d_{k+1} = r_{k+1} + \beta_{k,k+1} d_k$, $\beta_{k,k+1} = \beta_k = \frac{\langle r_{k+1}, r_{k+1} \rangle}{\langle r_k, r_k \rangle}$.

16. Теорема сходимости метода Ньютона для сильно выпуклых функций с Липшицевым гессианом.

i Пусть $f(x)$ — сильно выпуклая дважды непрерывно дифференцируемая функция на $\mathbb{R}^n$, для второй производной которой выполняются неравенства: $\mu I_n \preceq \nabla^2 f(x) \preceq L I_n$. Пусть также гессиан функции M -липшицев. Тогда метод Ньютона сходится локально к решению с квадратичной скоростью, т.е. при $\|x_0 - x^*\| < \frac{2\mu}{3M}$:

$$\|x_{k+1} - x^*\| \leq \frac{3M}{2\mu} \|x_k - x^*\|^2$$

Доказательство

1. Мы будем использовать формулу Ньютона-Лейбница

$$\nabla f(x_k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) (x_k - x^*) d\tau$$

2. Мы будем отслеживать расстояние до решения

$$\begin{aligned} x_{k+1} - x^* &= x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k) - x^* = x_k - x^* - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k) = \\ &= x_k - x^* - [\nabla^2 f(x_k)]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) (x_k - x^*) d\tau \end{aligned}$$

3.

$$\begin{aligned} &= \left(I - [\nabla^2 f(x_k)]^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau \right) (x_k - x^*) = \\ &= [\nabla^2 f(x_k)]^{-1} \left(\nabla^2 f(x_k) - \int_0^1 \nabla^2 f(x^* + \tau(x_k - x^*)) d\tau \right) (x_k - x^*) = \\ &= [\nabla^2 f(x_k)]^{-1} \left(\int_0^1 (\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*))) d\tau \right) (x_k - x^*) = \\ &= [\nabla^2 f(x_k)]^{-1} G_k(x_k - x^*) \end{aligned}$$

4. Введём:

$$G_k = \int_0^1 (\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*))) d\tau.$$

5. Попробуем оценить размер G_k с помощью $r_k = \|x_k - x^*\|$:

$$\begin{aligned} \|G_k\| &= \left\| \int_0^1 (\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*))) d\tau \right\| \leq \\ &\leq \int_0^1 \|\nabla^2 f(x_k) - \nabla^2 f(x^* + \tau(x_k - x^*))\| d\tau \leq \quad (\text{Липшицевость гессиана}) \\ &\leq \int_0^1 M \|x_k - x^* - \tau(x_k - x^*)\| d\tau = \int_0^1 M \|x_k - x^*\| (1 - \tau) d\tau = \frac{r_k}{2} M, \end{aligned}$$

6. Получаем:

$$r_{k+1} \leq \left\| [\nabla^2 f(x_k)]^{-1} \right\| \cdot \frac{r_k}{2} M \cdot r_k$$

и нам нужно оценить норму обратного гессиана

7. Из липшицевости и симметричности гессиана:

$$\begin{aligned} \nabla^2 f(x_k) - \nabla^2 f(x^*) &\succeq -Mr_k I_n \\ \nabla^2 f(x_k) &\succeq \nabla^2 f(x^*) - Mr_k I_n \\ \nabla^2 f(x_k) &\succeq \mu I_n - Mr_k I_n \\ \nabla^2 f(x_k) &\succeq (\mu - Mr_k) I_n \end{aligned}$$

8. Из сильной выпуклости следует, что $\nabla^2 f(x_k) \succ 0$, i.e. $r_k < \frac{\mu}{M}$.

$$\begin{aligned} \left\| [\nabla^2 f(x_k)]^{-1} \right\| &\leq (\mu - Mr_k)^{-1} \\ r_{k+1} &\leq \frac{r_k^2 M}{2(\mu - Mr_k)} \end{aligned}$$

9. Потребуем, чтобы верхняя оценка на r_{k+1} была меньше r_k , учитывая, что $0 < r_k < \frac{\mu}{M}$:

$$\begin{aligned} \frac{r_k^2 M}{2(\mu - Mr_k)} &< r_k \\ \frac{M}{2(\mu - Mr_k)} r_k &< 1 \\ Mr_k &< 2(\mu - Mr_k) \\ 3Mr_k &< 2\mu \\ r_k &< \frac{2\mu}{3M} \end{aligned}$$

10. Возвращаясь к оценке невязки на $k + 1$ -ой итерации, получаем:

$$r_{k+1} \leq \frac{r_k^2 M}{2(\mu - Mr_k)} < \frac{3Mr_k^2}{2\mu}$$

Таким образом, мы получили важный результат: метод Ньютона для функции с липшицевым положительно определённым гессианом сходится **квадратично** вблизи решения.

17. Теорема о сходимости метода проекции градиента для выпуклой гладкой функции.

i Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ выпуклая и дифференцируемая. Пусть $S \subseteq \mathbb{R}^n$ замкнутое выпуклое множество, и пусть x^* - минимизатор f на S ; кроме того, пусть f гладкая на S с параметром L . Метод проекции градиента с шагом $\frac{1}{L}$ достигает следующей оценки после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|^2}{2k}$$

1. Докажем лемму о достаточном убывании, предполагая, что $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ и теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

$$\text{Гладкость: } f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

$$\text{Метод: } = f(x_k) - L \langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

$$\begin{aligned} \cos : &= f(x_k) - \frac{L}{2} (\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2} \|x_{k+1} - x_k\|^2 \\ &= f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2 \end{aligned}$$

(17)

2. Снова используем теорему косинусов:

$$\begin{aligned} \left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right) \end{aligned}$$

3. Используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned} \|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2 \end{aligned}$$

4. Используя выпуклость и предыдущую часть:

$$\begin{aligned} \text{Выпуклость: } f(x_k) - f^* &\leq \langle \nabla f(x_k), x_k - x^* \rangle \\ &\leq \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right) \end{aligned}$$

Суммируем по $i = 0, k - 1$

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \frac{1}{2L} \|\nabla f(x_i)\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2$$

5. Оценим градиенты с помощью неравенства о достаточном убывании (17):

$$\begin{aligned} \sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) \end{aligned}$$

6. Из неравенства о достаточном убывании:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

7. Используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции:

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

8. Итак, $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ подразумевает, что $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$. Следовательно:

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставляем обратно в (*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

Следовательно:

$$f(x_{k+1}) \leq f(x_k) \quad \text{for each } k,$$

Следовательно, $\{f(x_k)\}$ является монотонно невозрастающей последовательностью.

9. Окончательная оценка сходимости: Из шага 5 мы уже установили:

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку $f(x_i)$ убывает в i , в частности $f(x_k) \leq f(x_i)$ для всех $i \leq k$. Следовательно:

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

Следовательно:

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|_2^2}{2k}.$$

18. Теорема о сходимости метода проекции градиента для сильно выпуклых гладких функций.

i Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ - μ -сильно выпуклая. Пусть $S \subseteq \mathbb{R}^n$ замкнутое выпуклое множество, и пусть x^* - минимизатор f на S ; кроме того, пусть f гладкая на S с параметром L . Метод проекции градиента с шагом $\alpha \leq \frac{1}{L}$ достигает следующей сходимости после итерации $k > 0$:

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2.$$

Для доказательства мы используем два факта:

1. Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ - L -гладкая выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ or, equivalently,}$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

2. Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ непрерывно дифференцируема на $\mathbb{R}^n$. Тогда функция f μ -сильно выпукла, если и только если для любых $x, y \in \mathbb{R}^n$ выполняется:

$$\text{Strongly convex case } \mu > 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

$$\text{Convex case } \mu = 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$$

Доказательство

1. Сначала докажем свойство стационарности метода: $\text{proj}_S(x^* - \alpha \nabla f(x^*)) = x^*$.

Это следует из критерия проекции и условия оптимальности первого порядка для x^* . Пусть $y = x^* - \alpha \nabla f(x^*)$. Мы должны показать, что $\langle y - x^*, x - x^* \rangle \leq 0$ для всех $x \in S$.

$$\langle (x^* - \alpha \nabla f(x^*)) - x^*, x - x^* \rangle = -\alpha \langle \nabla f(x^*), x - x^* \rangle \leq 0$$

Неравенство выполняется, потому что $\alpha > 0$ и $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ - условие оптимальности для x^* .

2. Рассмотрим расстояние до решения и используем свойство стационарности:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

$$\text{stationary point property} = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2$$

$$\text{nonexpansiveness} \leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2$$

$$= \|x_k - x^*\|_2^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2$$

3. Рассмотрим расстояние до решения и используем свойство стационарности:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

$$\text{stationary point property} = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2$$

$$\text{nonexpansiveness} \leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2$$

$$= \|x_k - x^*\|_2^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2$$

4. Используем гладкость и сильную выпуклость:

$$\text{smoothness} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 \leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)$$

$$\text{strong convexity} \quad - \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle \leq$$

$$- \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - \langle \nabla f(x^*), x_k - x^* \rangle$$

5. Подставляем:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

6. Из выпуклости f : $f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle \geq 0$. Следовательно, если мы используем $\alpha \leq \frac{1}{L}$:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 \\ \|x_k - x^*\|_2^2 &\leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2\end{aligned}$$

19. Теорема о сходимости метода Франк-Вульфа для выпуклых гладких функций.

i Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ выпуклая и дифференцируемая. Пусть $S \subseteq \mathbb{R}^n$ замкнутое выпуклое множество, и пусть x^* - минимизатор f на S ; кроме того, пусть f гладкая на S с параметром L . Метод Франк-Вульфа с шагом $\gamma_k = \frac{k-1}{k+1}$ достигает следующей оценки после итерации $k > 0$:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

где $R = \max_{x,y \in S} \|x - y\|$ - диаметр множества S .

Доказательство

1. Из гладкости f :

$$\begin{aligned}f(x_{k+1}) - f(x_k) &\leq \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2 \\ &= (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2\end{aligned}$$

2. Из выпуклости f , для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению y_k , мы имеем $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$, следовательно:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя неравенства:

$$\begin{aligned}f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2\end{aligned}$$

5. Перегруппируем:

$$f(x_{k+1}) - f(x^*) \leq \gamma_k (f(x_k) - f(x^*)) + (1 - \gamma_k)^2 \frac{LR^2}{2}$$

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, мы получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем, что $\delta_k \leq \frac{2}{k+1}$ по индукции.

- База: $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим, что $\delta_k \leq \frac{2}{k+1}$
- Тогда $\delta_{k+1} \leq \frac{k-1}{k+1} \cdot \frac{2}{k+1} + \frac{2}{(k+1)^2} = \frac{2k}{k^2+2k+1} < \frac{2}{k+2}$

Получаем желаемый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

20. Теорема о сходимости субградиентного метода для выпуклых Липшицевых функций. Стратегии выбора шага для сходимости. Как обеспечить сходимость с постоянным шагом, задаваемым заранее? Как обеспечить сходимость с убывающим шагом?

i Пусть f выпуклая и G -липшицева. Пусть $R = \|x_0 - x^*\|_2$. Для постоянного шага $\alpha = \frac{R}{G} \sqrt{\frac{1}{k}}$, субградиентный метод удовлетворяет

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}$$

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2 \end{aligned}$$

Суммируем полученное неравенство для $k = 0, \dots, T-1$:

$$\begin{aligned} \sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2 \end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$ на последней итерации:
- Для субградиента: $\langle g_k, x^* - x_k \rangle \leq f(x^*) - f(x_k)$.
- Дополнительно предполагаем, что $\|g_k\|^2 \leq G^2$
- Используем обозначение $R = \|x_0 - x^*\|_2$

Заметим, что:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \geq \sum_{k=0}^{T-1} 2\alpha_k (f_T^{\text{best}} - f(x^*)) = (f_T^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} 2\alpha_k$$

Получаем основное неравенство:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k}$$

Из этого следует, что если стратегия шага такая, что

$$\sum_{k=0}^{T-1} \alpha_k^2 < \infty, \quad \sum_{k=0}^{T-1} \alpha_k = \infty,$$

то субградиентный метод сходится (шаг должен быть убывающим, но не слишком быстро).

- Например, если $\alpha = \frac{R}{G} \sqrt{\frac{1}{T}}$, то:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 T \frac{R^2}{G^2} \frac{1}{T}}{2T \frac{R}{G} \sqrt{\frac{1}{T}}} = \frac{GR}{\sqrt{T}}$$

- Если $\alpha_k = \frac{R}{G\sqrt{k+1}}$, то:

1. Ограничим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

2. Уберем последний -1 в верхней оценке и используем основное неравенство:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k} \leq \frac{R^2 + R^2 (1 + \ln T)}{4 \frac{R}{G} (\sqrt{T+1})} = \frac{GR(2 + \ln T)}{4\sqrt{T+1}}$$

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

21. Теорема о сходимости субградиентного метода для сильно выпуклых Липшицевых функций.

i Пусть f - μ -сильно выпуклая функция (возможно, негладкая) с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. Используя шаг $\alpha_k = \frac{2}{\mu(k+1)}$, субградиентный метод гарантирует для $k > 0$ следующее:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}$$

Вспомогательный факт

Пусть f - μ -сильно выпуклая функция на выпуклом множестве и x, y - произвольные точки. Тогда для любого $g \in \partial f(x)$,

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого $\lambda \in [0, 1)$, из μ -сильной выпуклости:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

2. Из неравенства субградиента в x , мы имеем:

$$f(\lambda x + (1 - \lambda)y) \geq f(x) + \langle g, \lambda x + (1 - \lambda)y - x \rangle \rightarrow f(\lambda x + (1 - \lambda)y) \geq f(x) - (1 - \lambda) \langle g, x - y \rangle.$$

3. Следовательно,

$$\begin{aligned} f(x) - (1 - \lambda) \langle g, x - y \rangle &\leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2 \\ (1 - \lambda)f(x) &\leq (1 - \lambda)f(y) + (1 - \lambda) \langle g, x - y \rangle - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2 \\ f(x) &\leq f(y) + \langle g, x - y \rangle - \frac{\mu}{2} \lambda \|x - y\|^2 \end{aligned}$$

4. Пусть $\lambda \rightarrow 1^-$ получаем $f(x) \leq f(y) + \langle g, x - y \rangle - \frac{\mu}{2} \|x - y\|^2 \rightarrow \langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$

Доказательство

1. Начнем с формулировки метода как и раньше:

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2 \\ &= (1 - \mu \alpha_k) \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ 2\alpha_k (f(x_k) - f(x^*)) &\leq (1 - \mu \alpha_k) \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2 \\ f(x_k) - f(x^*) &\leq \frac{1 - \mu \alpha_k}{2\alpha_k} \|x_k - x^*\|^2 - \frac{1}{2\alpha_k} \|x_{k+1} - x^*\|^2 + \frac{\alpha_k}{2} \|g_k\|^2 \end{aligned}$$

2. Подставляем шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$\begin{aligned} f(x_k) - f(x^*) &\leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2 \\ f(x_k) - f(x^*) &\leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2 \\ k(f(x_k) - f(x^*)) &\leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2 \end{aligned}$$

3. Суммируем неравенства для всех $k = 0, 1, \dots, T-1$, получаем:

$$\begin{aligned} \sum_{k=0}^{T-1} k (f(x_k) - f(x^*)) &\leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu} \\ (f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k &= \sum_{k=0}^{T-1} k (f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k (f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu} \\ f_{T-1}^{\text{best}} - f(x^*) &\leq \frac{G^2 T}{\mu \sum_{k=0}^{T-1} k} = \frac{2G^2 T}{\mu T(T-1)} \quad f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}. \end{aligned}$$

22. Вывод формул обновления оценок обратного гессиана и гессиана квазиньютоновских методов SR-1, DFP, BFGS.

$$\begin{aligned} x_{k+1} &= x_k + \alpha_k d_k, \\ B_k d_k &= -\nabla f(x_k) \\ B_k &= \nabla^2 f(x_k) \end{aligned}$$

То есть на каждой итерации необходимо вычислять гессиан и решать систему линейных уравнений.

В квази-ньютоновских методах мы рассматриваем последовательность матриц B_k , сходящихся в каком-то смысле к настоящему значению обратного Гессиана в локальном оптимуме: $[\nabla^2 f(x^*)]^{-1}$.

Общая схема:

1. Решить $B_k d_k = -\nabla f(x_k)$
2. Обновить $x_{k+1} = x_k + \alpha_k d_k$ (уравнения секущих)
3. Вычислить B_{k+1} из B_k

Требования к B_{k+1} из ур-я секущих:

$$\begin{aligned} \nabla f(x_{k+1}) - \nabla f(x_k) &= B_{k+1}(x_{k+1} - x_k) = B_{k+1} d_k \\ \Delta y_k &= B_{k+1} d_k \end{aligned}$$

Также требуем:

- B_{k+1} - симметрична
- B_{k+1} "близка" к B_k
- $B_k \succ 0 \Rightarrow B_{k+1} \succ 0$

1. Symmetric Rank-One (Broyden) Update

Поробуем такой вид обновления:

$$B_{k+1} = B_k + a u u^T$$

уравнение секущих $B_{k+1} d_k = \Delta y_k$ приводит к:

$$(a u^T d_k) u = \Delta y_k - B_k d_k$$

Это справедливо только в том случае, если u кратно $\Delta y_k - B_k d_k$. Полагая $u = \Delta y_k - B_k d_k$, мы решаем приведенную выше задачу,

$$a = \frac{1}{(\Delta y_k - B_k d_k)^T d_k},$$

Что приводит к:

$$B_{k+1} = B_k + \frac{(\Delta y_k - B_k d_k)(\Delta y_k - B_k d_k)^T}{(\Delta y_k - B_k d_k)^T d_k}$$

Называется симметричный одноранговый апдейт (SR1) или метод Бройдена.

2. Davidon-Fletcher-Powell Update (DFP)

Как мы можем решить

$$B_{k+1} d_{k+1} = -\nabla f(x_{k+1}),$$

для того, чтобы сделать следующий шаг? В дополнение к приведению B_k к B_{k+1} , давайте будем приводить обратные, т.е. $C_k = B_k^{-1}$ to $C_{k+1} = (B_{k+1})^{-1}$.

Sherman-Morrison Formula: Формула Шермана-Моррисона утверждает:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}$$

$$C_{k+1} = C_k + a u u^T + b v v^T.$$

Умножая на Δy_k и используя уравнение текущих $d_k = C_{k+1} \Delta y_k$ имеет:

$$d_k = C_k \Delta y_k + (a u^T \Delta y_k) u + (b v^T \Delta y_k) v$$

Полагая $u = C_k \Delta y_k$, $v = d_k$ и решая для a, b получаем:

$$(1 + a \Delta y_k^T C \Delta y_k) C_k \Delta y_k + (b d_k^T \Delta y_k - 1) d_k \Leftrightarrow a = -\frac{1}{\Delta y_k^T C \Delta y_k}, b = \frac{1}{\Delta y_k^T d_k}$$

$$C_{k+1} = C_k - \frac{C_k \Delta y_k \Delta y_k^T C_k}{\Delta y_k^T C_k \Delta y_k} + \frac{d_k d_k^T}{\Delta y_k^T d_k}$$

Woodbury Formula Application Формула показывает:

$$B_{k+1} = \left(I - \frac{\Delta y_k d_k^T}{\Delta y_k^T d_k} \right) B_k \left(I - \frac{d_k \Delta y_k^T}{\Delta y_k^T d_k} \right) + \frac{\Delta y_k \Delta y_k^T}{\Delta y_k^T d_k}$$

Это обновление Davidon-Fletcher-Powell (DFP). Также дешево: $\mathcal{O}(n^2)$, сохраняет положительную определенность. Не так популярно, как BFGS.

3. Broyden-Fletcher-Goldfarb-Shanno update

Давайте теперь попробуем обновление второго ранга:

$$B_{k+1} = B_k + auu^T + bvv^T.$$

Умножая на Δy_k и используя уравнение текущих $\Delta y_k = B_{k+1}d_k$ имеем:

$$\Delta y_k - B_k d_k = (au^T d_k)u + (bv^T d_k)v$$

Полагая $u = \Delta y_k, v = B_k d_k$, и решая для a, b мы получаем:

$$(1 - a\Delta y_k^T d_k)\Delta y_k - (1 + b d_k^T B_k d_k)B_k d_k \Leftrightarrow a = \frac{1}{y_k^T d_k}, b = -\frac{1}{d_k^T B_k d_k}$$

$$B_{k+1} = B_k - \frac{B_k d_k d_k^T B_k}{d_k^T B_k d_k} + \frac{\Delta y_k \Delta y_k^T}{d_k^T \Delta y_k}$$

называется обновлением Бройдена-Флетчера-Гольдфарба-Шанно (BFGS).

23. Теорема о сходимости проксимального градиентного метода для выпуклой гладкой функции f .

i Рассматриваем задачу

$$\varphi(x) \rightarrow \min_{x \in \mathbb{R}^d}.$$

Причем $\varphi(x) = f(x) + r(x)$, и

- f -выпуклая и L -гладкая, $\text{dom } f = \mathbb{R}^n$
- r - выпуклая и $\text{prox}_{\alpha r}(x_k) = \arg \min_{x \in \mathbb{R}^n} [\alpha r(x) + \frac{1}{2}\|x - x_k\|^2]$ может быть вычислен

Тогда для проксимального метода с фиксированным шагом $\alpha = \frac{1}{L}$

$$x_{k+1} = \text{prox}_{\alpha, r} \left(x_k - \frac{1}{L} \nabla f(x_k) \right)$$

выполняется

$$\varphi(x_k) - \varphi^* \leq \frac{L\|x_0 - x^*\|^2}{2k},$$

То есть имеет место сублинейная сходимость.

1. Представим отображение градиента, обозначаемое как $G_\alpha(x)$, действует как “градиентоподобный объект”:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

$$x_{k+1} = x_k - \alpha G_\alpha(x_k).$$

где $G_\alpha(x)$ имеет вид:

$$G_\alpha(x) = \frac{1}{\alpha} (x - \text{prox}_{\alpha r}(x - \alpha \nabla f(x)))$$

$G_\alpha(x) = 0 \Leftrightarrow x = x^* \Rightarrow G_\alpha$ аналогичен ∇f .

2. L -гладкость:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|_2^2$$

Выпуклость:

$$f(x) \geq f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

$$\begin{aligned} f(x_{k+1}) &\leq f(x) - \langle \nabla f(x_k), x - x_k \rangle + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2 \leq \\ &\leq f(x) + \langle \nabla f(x_k), x_{k+1} - x \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2 \quad (1) \end{aligned}$$

3. Воспользуемся свойством проксимального оператора:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) \Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1})$$

$$x_k - x_{k+1} = \alpha G_\alpha(x_k) \Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1})$$

$$G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})$$

4. По определению субградиента:

$$r(x) \geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1})$$

$$r(x) \geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle$$

$$r(x) \geq r(x_{k+1}) + \langle G_\alpha(x_k), x - x_{k+1} \rangle - \langle \nabla f(x_k), x - x_{k+1} \rangle$$

$$\langle \nabla f(x_k), x_{k+1} - x \rangle \leq r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle$$

5. Подставляем полученные результаты в (1):

$$f(x_{k+1}) \leq f(x) + \langle \nabla f(x_k), x_{k+1} - x \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

$$f(x_{k+1}) \leq f(x) + r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

$$f(x_{k+1}) + r(x_{k+1}) \leq f(x) + r(x) - \langle G_\alpha(x_k), x - x_k + \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

6. Используя $\varphi(x) = f(x) + r(x)$ доказываем монотонное уменьшение итерации:

$$\varphi(x_{k+1}) \leq \varphi(x) - \langle G_\alpha(x_k), x - x_k \rangle - \langle G_\alpha(x_k), \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

$$\varphi(x_{k+1}) \leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle + \frac{\alpha}{2} (\alpha L - 2) \|G_\alpha(x_k)\|_2^2$$

$$\left(\alpha \leq \frac{1}{L} \Rightarrow \frac{\alpha}{2} (\alpha L - 2) \leq -\frac{\alpha}{2} \right) \Rightarrow \varphi(x_{k+1}) \leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

$$x := x_k \Rightarrow \varphi(x_{k+1}) \leq \varphi(x_k) - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

7. Рассмотрим теперь $x = x^*$:

$$\begin{aligned}\varphi(x_{k+1}) &\leq \varphi(x^*) + \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ \varphi(x_{k+1}) - \varphi(x^*) &\leq \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2] \leq \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2 - \|x_k - x^*\|_2^2 + \|x_k - x^*\|_2^2] \leq \\ &\leq \frac{1}{2\alpha} [-\|x_k - x^* - \alpha G_\alpha(x_k)\|_2^2 + \|x_k - x^*\|_2^2] \leq \frac{1}{2\alpha} [\|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2]\end{aligned}$$

8. Суммируем $i = \overline{0, k-1}$ и суммируем их:

$$\sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] \leq \frac{1}{2\alpha} [\|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2] \leq \frac{1}{2\alpha} \|x_0 - x^*\|_2^2$$

9. Поскольку $\{\varphi(x_{i+1}) - \varphi(x^*)\}$ является убывающей последовательностью, из этого следует, что:

$$\begin{aligned}k\varphi(x_k) &\leq \sum_{i=0}^{k-1} \varphi(x_{i+1}) \Rightarrow \varphi(x_k) \leq \frac{1}{k} \sum_{i=0}^{k-1} \varphi(x_{i+1}) \\ \varphi(x_k) - \varphi(x^*) &\leq \frac{1}{k} \sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] \leq \frac{\|x_0 - x^*\|_2^2}{2\alpha k} = \frac{L\|x_0 - x^*\|_2^2}{2k}\end{aligned}$$

То есть имеет место сублинейная сходимость.

24. Теорема о сходимости проксимального градиентного метода для сильно выпуклой гладкой функции f .

i Рассматриваем задачу

$$\varphi(x) \rightarrow \min_{x \in \mathbb{R}^d}$$

Пусть $\varphi(x) = f(x) + r(x)$, причем

- f - μ -сильно выпуклая, L -гладкая, $\text{dom } f = \mathbb{R}^n$
- r - выпуклая и $\text{prox}_{\alpha r}(x_k) = \arg \min_{x \in \mathbb{R}^n} [\alpha r(x) + \frac{1}{2} \|x - x_k\|_2^2]$ может быть вычислен

Тогда проксимальный градиентный спуск с фиксированным шагом $\alpha \leq \frac{1}{L}$

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

сходится линейно, то есть имеет место

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$$

$$\|x_{k+1} - x^*\|_2^2 = \|\text{prox}_{\alpha f}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \stackrel{1}{=} \|\text{prox}_{\alpha f}(x_k - \alpha \nabla f(x_k)) - \text{prox}_{\alpha f}(x^* - \alpha \nabla f(x^*))\|_2^2 \stackrel{2}{\leq}$$

$$\leq \|x_k - \alpha \nabla f(x_k) - x^* + \alpha \nabla f(x^*)\|_2^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2$$

Воспользуемся L -гладкостью и сильной выпуклостью

$$\begin{aligned} \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 &\leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ -\langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle &\leq -\left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2\right) - \langle \nabla f(x^*), x_k - x^* \rangle \end{aligned}$$

Подставляем

$$\begin{aligned} \|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2\right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \end{aligned}$$

Так как f выпуклая: $f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle \geq 0$ и при $\alpha \leq \frac{1}{L}$:

$$\|x_{k+1} - x^*\|_2^2 \leq (1 - \alpha\mu) \|x_k - x^*\|^2,$$

что и является линейной сходимостью с параметром $1 - \frac{\mu}{L}$.

0. Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ выпуклая функция, для которой определен prox_r . Тогда $\forall x, y \in \mathbb{R}^n$, следующие условия эквивалентны:

- $\text{prox}_r(x) = y$,
- $x - y \in \partial r(y)$,
- $\langle x - y, z - y \rangle \leq r(z) - r(y)$ for any $z \in \mathbb{R}^n$.

Доказательство.

1 $\Leftrightarrow$ 2. Первое условие может быть переписано в виде

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|^2 \right).$$

Из условия оптимальности для выпуклой функции r , это эквивалентно:

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x \Leftrightarrow x - y \in \partial r(y).$$

2 $\Rightarrow$ 3. По определению субдифференциала, $\forall g \in \partial r(y)$, $\forall z \in \mathbb{R}^d$:

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности, это верно для $g = x - y \Rightarrow \langle x - y, z - y \rangle \leq r(z) - r(y)$

3 $\Rightarrow$ 2. Пусть выполняется $\langle x - y, z - y \rangle \leq r(z) - r(y) \Rightarrow$ по определению субградиента $x - y \in \partial r(y)$.

1. Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ и $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ выпуклые функции. Пусть f - L -гладкая, и для r определен оператор prox_r . Тогда, x^* - решение составной задачи оптимизации $\Leftrightarrow \forall \alpha > 0$, выполняется:

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Доказательство. Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$\begin{aligned} -\alpha \nabla f(x^*) &\in \alpha \partial r(x^*) \\ x^* - \alpha \nabla f(x^*) - x^* &\in \alpha \partial r(x^*) \end{aligned}$$

Воспользуемся пунктом 0:

$$\text{prox}_r(x) = y \Leftrightarrow x - y \in \partial r(y) \Rightarrow x^* = \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*)) = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*)).$$

2. Оператор $\text{prox}_r(x)$ - firmly nonexpansive, т. е.

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq \langle \text{prox}_r(x) - \text{prox}_r(y), x - y \rangle$$

и nonexpansive:

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2.$$

Доказательство. Пусть $u = \text{prox}_r(x)$, and $v = \text{prox}_r(y)$. Тогда из пункта 0:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u)$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

Полагая $z_1 = v$ и $z_2 = u$ и суммируя, получаем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0$$

$$\langle x - y, v - u \rangle + \|v - u\|_2^2 \leq 0$$

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \Rightarrow \|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq \langle \text{prox}_r(x) - \text{prox}_r(y), x - y \rangle$$

Применяя неравенство Коши-Буняковского:

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \leq \|x - y\| \|u - v\| \Rightarrow \|u - v\| \leq \|x - y\| \Rightarrow \|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|$$

3. Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ - L -гладкая выпуклая функция. тогда $\forall x, y \in \mathbb{R}^n$, следующее неравенство сохраняются:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \Leftrightarrow$$

$$\Leftrightarrow \|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Доказательство. Рассмотрим другую функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она, выпуклая как сумма выпуклых функций, а также L -гладкая, так как $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$. То есть для φ выполняется $\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$.

$$x := y, y := y - \frac{1}{L} \nabla \varphi(y) \Rightarrow \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

$$\varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) - \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

По дифференциальному критерию первого порядка, оптимальная точка для φ определяется условием: $\nabla \varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Поэтому $\forall x$, минимум функции $\varphi(y)$ находится в точке $y = x$. Тогда:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) - \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

Наконец, подставляем $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L} \|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L (f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

$$\text{меняем местами } x \text{ и } y \Rightarrow \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

25. Теорема о сходимости стохастического градиентного спуска в гладком PL-случае.

i Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда стохастический градиентный спуск с убывающим шагом $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

Доказательство.

1. Используем L -гладкость:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Используя формулировку метода (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

3. Возьмем математическое ожидание по i_k :

$$\mathbb{E}[f(x_{k+1})] \leq \mathbb{E}[f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2]$$

4. Используем линейность математического ожидания:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \mathbb{E}[\nabla f_{i_k}(x_k)] \rangle + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

5. Так как равномерное выборка означает несмещенную оценку градиента: $\mathbb{E}[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

6. Используем PL-условие:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*) \leq f(x_k) - 2\alpha_k \mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Вычитаем } f^* \leq (f(x_k) - f^*) - 2\alpha_k \mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Перегруппируем} \leq (1 - 2\alpha_k \mu)[f(x_k) - f^*] + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Ограниченность дисперсии: } \mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2 \leq (1 - 2\alpha_k \mu)[f(x_k) - f^*] + \frac{L\sigma^2 \alpha_k^2}{2}.$$

7. Рассмотрим **убывающий** шаг с $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ мы получаем:

$$\begin{aligned} 1 - 2\alpha_k\mu &= \frac{(k+1)^2}{(k+1)^2} - \frac{2k+1}{(k+1)^2} = \frac{k^2}{(k+1)^2} \quad \mathbb{E}[f(x_{k+1}) - f^*] \leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2(2k+1)^2}{8\mu^2(k+1)^4} \\ (2k+1)^2 &< (2k+2)^2 = 4(k+1)^2 \quad \leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2}{2\mu^2(k+1)^2} \end{aligned}$$

8. Умножаем обе стороны на $(k+1)^2$ и пусть $\delta_f(k) \equiv k^2 \mathbb{E}[f(x_k) - f^*]$ мы получаем:

$$\begin{aligned} (k+1)^2 \mathbb{E}[f(x_{k+1}) - f^*] &\leq k^2 \mathbb{E}[f(x_k) - f^*] + \frac{L\sigma^2}{2\mu^2} \\ \delta_f(k+1) &\leq \delta_f(k) + \frac{L\sigma^2}{2\mu^2}. \end{aligned}$$

9. Суммируем предыдущее неравенство от $i = 0$ до k и используем тот факт, что $\delta_f(0) = 0$ мы получаем:

$$\begin{aligned} \delta_f(i+1) &\leq \delta_f(i) + \frac{L\sigma^2}{2\mu^2} \\ \sum_{i=0}^k [\delta_f(i+1) - \delta_f(i)] &\leq \sum_{i=0}^k \frac{L\sigma^2}{2\mu^2} \\ \delta_f(k+1) - \delta_f(0) &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ (k+1)^2 \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ \mathbb{E}[f(x_k) - f^*] &\leq \frac{L\sigma^2}{2\mu^2 k} \end{aligned}$$